Projet_MA_vins_Gaudin_Le-Meur

2024

Contents

Introduction **2**
Sujet . . . 2
Importation des données . . . 2

I Analyse univariée **3**
Summary . . . 3
Histogrammes . . . 4
Boxplots . . . 5
Interprétation . . . 7

II Analyse multivariée **7**
Coéfficients de corrélation . . . 7
ACP . . . 10

III Classification des pays **17**
Classification ascendante hierarchique . . . 17
K-means . . . 22
DBSCAN . . . 31

IV Interprétation **33**

Introduction

Sujet

Fichier : *vins.xls*

La consommation de plusieurs types de vins (exprimee en KiloLitres/an) est observee dans plusieurs pays.

Objectif : Analyse descriptive multivariée, classification des pays.

Importation des données

Dans un premier temps on importe les données en ajoutant les noms de vins comme titre des lignes:

```
vins <- read_excel("vins.xls")
vins=t(vins)
d<-vins[2:9,]
colnames(d)=vins[1,1:18]
d<-as.data.frame(d)
nomcol=colnames(d)
for (i in nomcol){
  d[,i]=as.integer(d[,i])
}
```

```
head(d)
```

```
##           CHMPAGNE MOUSSEAU_AOC MOUSSEAU_SIMPLE ALSACE GIRONDE BOJOLAIS
## BELGIQUE      7069         2436            3066   2422   22986    17465
## NEDERLAND     3786          586             290   1999   22183    19840
## RFA          12578         2006           10439  17183   21023    72977
## ITALIE        8037           30            1413     57      56     2364
## UK           13556         1217            7214   1127   30025    39919
## SUISSE        9664          471             112    600    6544    17327
##           BORDEAUX  RHON ANJOU AOC_AUTRES VDQS AUTRE_VDQS PROVENCE MUSCAT RHONE
## BELGIQUE      3784  7950  2587      17200 1976      38747     1375   2016   785
## NEDERLAND     2339 10537   600      22806 1029      19151     1150   2908  1648
## RFA           4828  7552  2101      15979 1346     191140     2514   1529  1009
## ITALIE          98    24     0         50    0       7992        0      0     6
## UK            7885  8172  7582      20004 2258     101108      284  12891   775
## SUISSE        3191 11691   143       1279  212       1029      401     18   643
##           AOC_FORT AUTRE_FORT TRES_FORT
## BELGIQUE       160         24      2415
## NEDERLAND      246       1533        74
## RFA            135        160       208
## ITALIE           8          0         8
## UK            1177        480      1705
## SUISSE          26          0        12
```

```
str(d)
```

```
## 'data.frame':    8 obs. of  18 variables:
##  $ CHMPAGNE       : int  7069 3786 12578 8037 13556 9664 10386 206
##  $ MOUSSEAU_AOC   : int  2436 586 2006 30 1217 471 997 51
##  $ MOUSSEAU_SIMPLE: int  3066 290 10439 1413 7214 112 3788 330
##  $ ALSACE         : int  2422 1999 17183 57 1127 600 408 241
##  $ GIRONDE        : int  22986 22183 21023 56 30025 6544 13114 3447
##  $ BOJOLAIS       : int  17465 19840 72977 2364 39919 17327 17487 2346
##  $ BORDEAUX       : int  3784 2339 4828 98 7885 3191 11791 1188
```

```
##  $ RHON           : int  7950 10537 7552 24 8172 11691 1369 1798
##  $ ANJOU          : int  2587 600 2101 0 7582 143 872 131
##  $ AOC_AUTRES     : int  17200 22806 15979 50 20004 1279 4016 944
##  $ VDQS           : int  1976 1029 1346 0 2258 212 1017 487
##  $ AUTRE_VDQS     : int  38747 19151 191140 7992 101108 1029 26192 38503
##  $ PROVENCE       : int  1375 1150 2514 0 284 401 9 236
##  $ MUSCAT         : int  2016 2908 1529 0 12891 18 716 653
##  $ RHONE          : int  785 1648 1009 6 775 643 542 35
##  $ AOC_FORT       : int  160 246 135 8 1177 26 7 0
##  $ AUTRE_FORT     : int  24 1533 160 0 480 0 0 0
##  $ TRES_FORT      : int  2415 74 208 8 1705 12 36 47
```

I Analyse univariée

Summary

Pour commencer l'analyse univarié on regarde le *summary*:

```
stat_uni = function(x)
{
return(c(

min(x, na.rm=TRUE),
max(x, na.rm=TRUE),
mean(x, na.rm=TRUE),
median(x, na.rm=TRUE),
quantile(x, 0.25, na.rm=TRUE),
quantile(x,0.75, na.rm=TRUE),
sd(x, na.rm=TRUE)))
}
res_stat_uni = apply(d, 2, "stat_uni")
row.names(res_stat_uni) = c( "Min", "Max", "Moyenne", "Mediane", "Quantile 1", "Quantile 3", "Ecart-typ
#print(round(t(res_stat_uni),3))
knitr::kable(round(t(res_stat_uni),3), format = "markdown", align = 'r')
```

	Min	Max	Moyenne	Mediane	Quantile 1	Quantile 3	Ecart-type
CHMPAGNE	206	13556	8160.250	8850.5	6248.25	10934.00	4463.439
MOUSSEAU_AOC	30	2436	974.250	791.5	366.00	1414.25	879.014
MOUSSEAU_SIMPLE	112	10439	3331.500	2239.5	320.00	4644.50	3744.993
ALSACE	57	17183	3004.625	863.5	366.25	2104.75	5791.044
GIRONDE	56	30025	14922.250	17068.5	5769.75	22383.75	10751.786
BOJOLAIS	2346	72977	23715.625	17476.0	13586.25	24859.75	23100.669
BORDEAUX	98	11791	4388.000	3487.5	2051.25	5592.25	3814.767
RHON	24	11691	6136.625	7751.0	1690.75	8763.25	4449.187
ANJOU	0	7582	1752.000	736.0	140.00	2222.50	2540.963
AOC_AUTRES	50	22806	10284.750	9997.5	1195.25	17901.00	9590.853
VDQS	0	2258	1040.625	1023.0	418.25	1503.50	804.176
AUTRE_VDQS	1029	191140	52982.750	32347.5	16361.25	54337.25	63697.361
PROVENCE	0	2514	746.125	342.5	179.25	1206.25	876.432
MUSCAT	0	12891	2591.375	1122.5	494.25	2239.00	4280.421
RHONE	6	1648	680.375	709.0	415.25	841.00	528.614
AOC_FORT	0	1177	219.875	80.5	7.75	181.50	397.078
AUTRE_FORT	0	1533	274.625	12.0	0.00	240.00	534.965

	Min	Max	Moyenne	Mediane	Quantile 1	Quantile 3	Ecart-type
TRES_FORT	8	2415	563.125	60.5	30.00	582.25	945.276

Histogrammes

Esnuite on peut aussi observer les différents *Histogrammes*:

```
par(mfrow=c(2,5))
for(i in 2:ncol(d))
{
hist(d[,names(d)[i]], xlab = names(d)[i], ylab = "fréquence", col = "blue", main = names(d)[i])
}
```

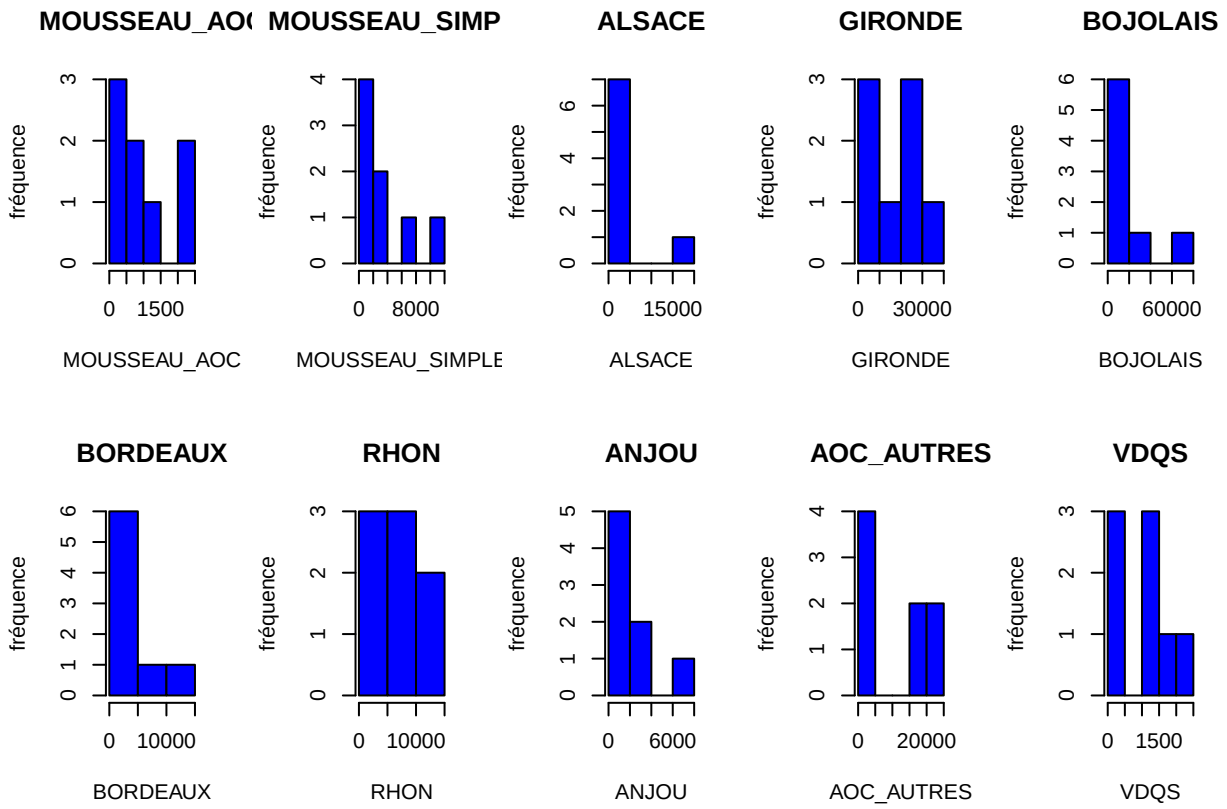

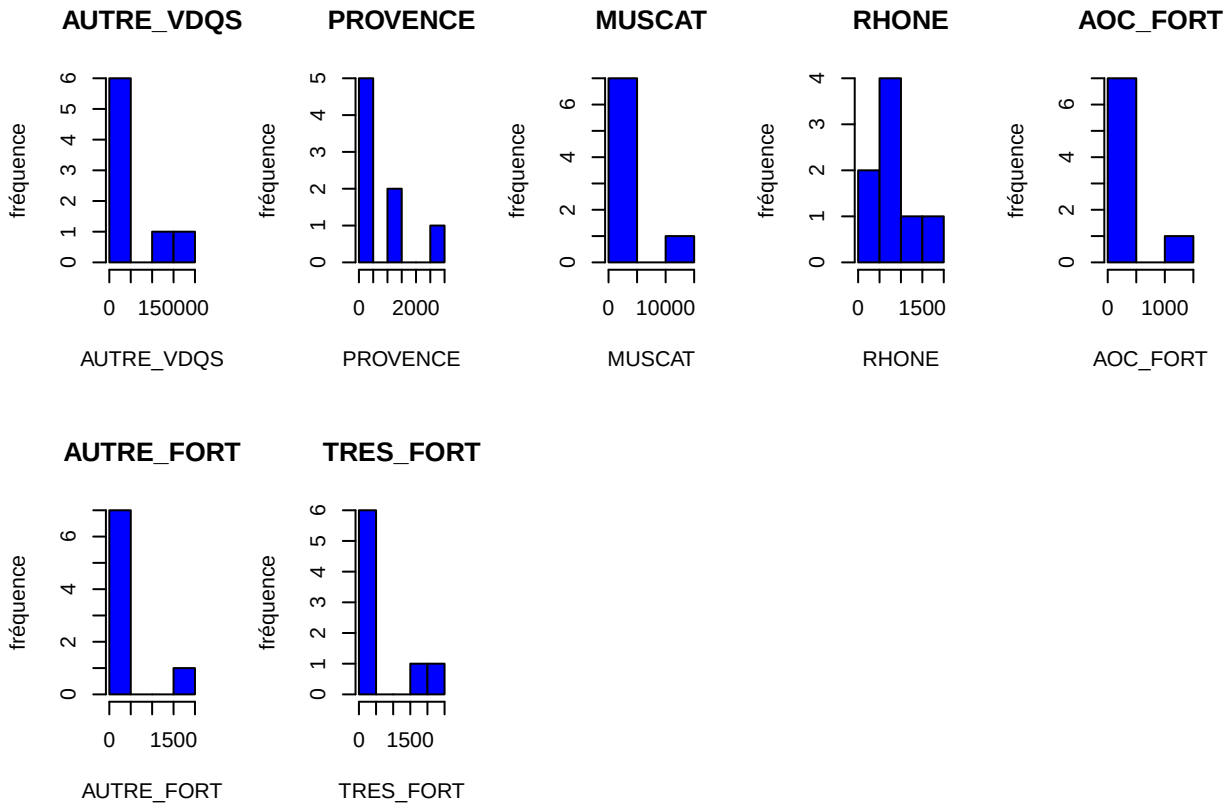

Boxplots

Et enfin des *Boxplots* peuvent être crées :

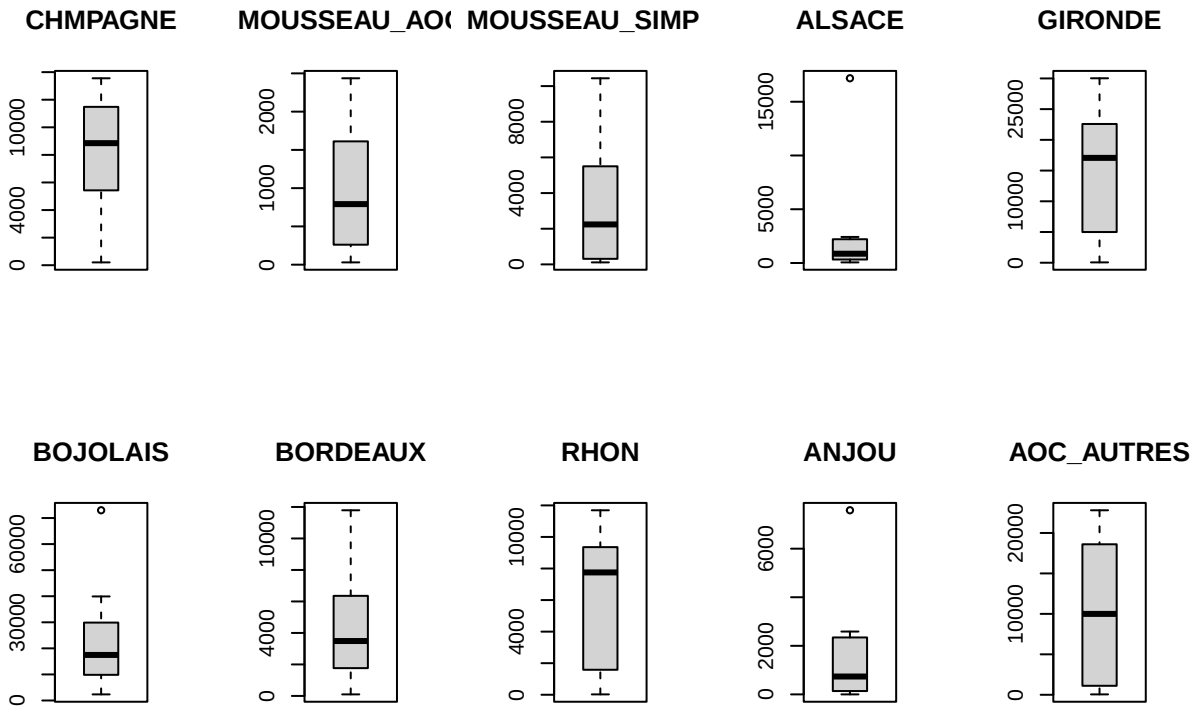
CHMPAGNE
MOUSSEAU_AO(
MOUSSEAU_SIMP
ALSACE
GIRONDE
BOJOLAIS
BORDEAUX
RHON
ANJOU
AOC_AUTRES

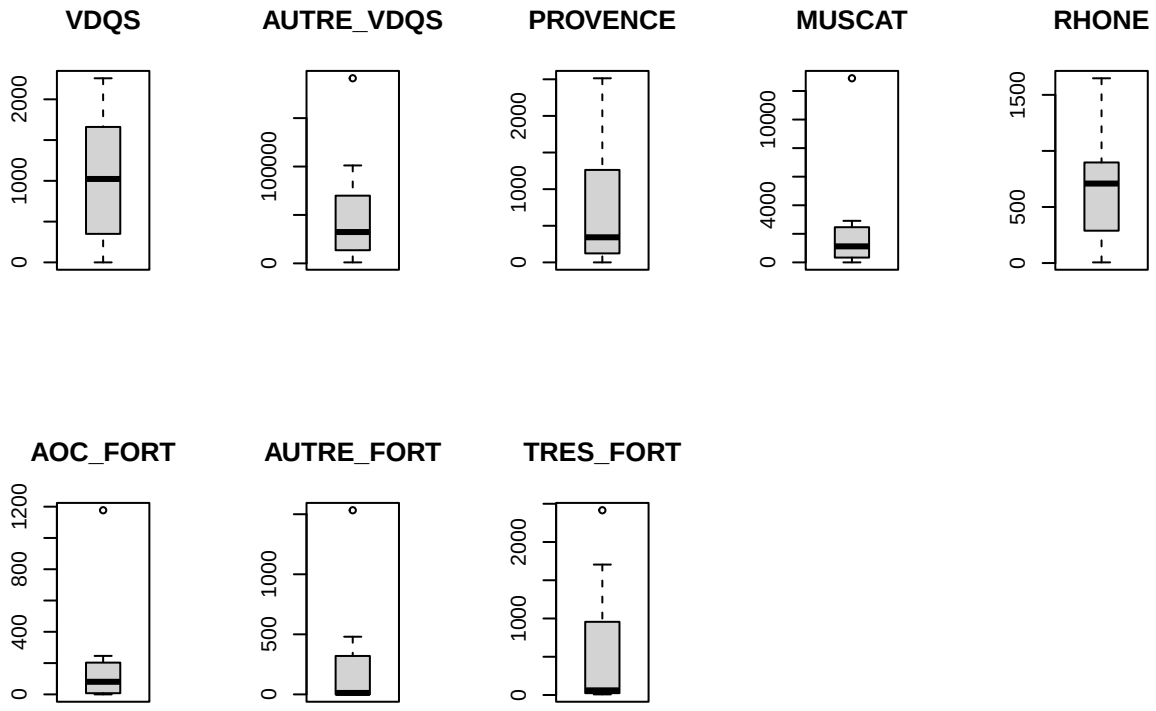

Interprétation

Dans un premier temps on observe qu'il n'y à pas de données manquantes. De plus les valeurs vont de *0* comme *minimum* à *191140* comme *maximum* (AUTRE_VDQS). Ensuite on remarque que La moyenne des mesures varie fortement selon les catégories de vin, allant de 0 à 52982.75, et de même la médiane varie aussi en fonction des catégories de vin, ce qui indique une certaine asymétrie dans les distributions. Pour terminer l'écart-type représente la dispersion des données autour de la moyenne, ces valeurs varient considérablement selon les catégories de vin, suggérant des degrés différents de dispersion ou de variabilité des données.

Conclusion: Pour résumer, l'analyse univariée met en évidence des écarts significatifs dans les mesures statistiques observées pour chaque catégorie de vin. Ces différences peuvent être attribuées aux caractéristiques uniques et aux volumes de production spécifiques à chaque type de vin.

II Analyse multivariée

Coéfficients de corrélation

Afin de voir les relations entre les différentes variables, et dans le but de ne pas avoir de colinéarité dans les futurs modèles, on commence par afficher la matrice des corrélations.

```
cor=cov.wt(d, method="ML", cor=TRUE)$cor
cor<-as.data.frame(cor)
```

	CHMPAGNE	MOUSSEAU_MOUSSEAU_AOC	MOUSSEAU_SUPERIEUR	ALSACE	GIRONDE	BOJOLAIS	BORDEAUX	RHON	ANJOU
CHMPAGNE	1.00	0.46	0.74	0.39	0.43	0.66	0.60	0.21	0.58
MOUSSEAU_AOC	0.46	1.00	0.66	0.57	0.72	0.63	0.38	0.36	0.47

	CHMPAGNE	MOUSSEAU_AOC	MOUSSEAU_SIMPLE	ALSACE	GIRONDE	BOJOLAIS	BORDEAUX	RHON	ANJOU
MOUSSEAU_SIMPLE	0.74	0.66	1.00	0.77	0.59	0.91	0.48	0.08	0.62
ALSACE	0.39	0.57	0.77	1.00	0.34	0.89	0.05	0.22	0.10
GIRONDE	0.43	0.72	0.59	0.34	1.00	0.63	0.46	0.56	0.78
BOJOLAIS	0.66	0.63	0.91	0.89	0.63	1.00	0.34	0.41	0.48
BORDEAUX	0.60	0.38	0.48	0.05	0.46	0.34	1.00	-0.04	0.45
RHON	0.21	0.36	0.08	0.22	0.56	0.41	-0.04	1.00	0.28
ANJOU	0.58	0.47	0.62	0.10	0.78	0.48	0.45	0.28	1.00
AOC_AUTRES	0.21	0.61	0.45	0.36	0.93	0.56	0.18	0.60	0.60
VDQS	0.41	0.79	0.62	0.25	0.93	0.53	0.51	0.35	0.84
AUTRE_VDQS	0.51	0.58	0.93	0.88	0.53	0.93	0.24	0.15	0.50
PROVENCE	0.18	0.71	0.57	0.89	0.50	0.76	-0.10	0.47	0.08
MUSCAT	0.43	0.23	0.44	-0.06	0.72	0.35	0.37	0.29	0.95
RHONE	0.15	0.43	0.22	0.36	0.74	0.50	0.17	0.76	0.22
AOC_FORT	0.46	0.22	0.45	-0.05	0.71	0.36	0.34	0.33	0.95
AUTRE_FORT	-0.21	-0.08	-0.12	-0.01	0.49	0.11	-0.10	0.48	0.12
TRES_FORT	0.23	0.70	0.28	-0.05	0.65	0.14	0.18	0.28	0.70

	AOC_AUTRES	VDQS	AUTRE_VDQS	PROVENCE	MUSCAT	RHONE	AOC_FORT	AUTRE_FORT	TRES_FORT
CHMPAGNE	0.21	0.41	0.51	0.18	0.43	0.15	0.46	-0.21	0.23
MOUSSEAU_AOC	0.61	0.79	0.58	0.71	0.23	0.43	0.22	-0.08	0.70
MOUSSEAU_SIMPLE	0.45	0.62	0.93	0.57	0.44	0.22	0.45	-0.12	0.28
ALSACE	0.36	0.25	0.88	0.89	-0.06	0.36	-0.05	-0.01	-0.05
GIRONDE	0.93	0.93	0.53	0.50	0.72	0.74	0.71	0.49	0.65
BOJOLAIS	0.56	0.53	0.93	0.76	0.35	0.50	0.36	0.11	0.14
BORDEAUX	0.18	0.51	0.24	-0.10	0.37	0.17	0.34	-0.10	0.18
RHON	0.60	0.35	0.15	0.47	0.29	0.76	0.33	0.48	0.28
ANJOU	0.60	0.84	0.50	0.08	0.95	0.22	0.95	0.12	0.70
AOC_AUTRES	1.00	0.80	0.46	0.60	0.60	0.84	0.60	0.69	0.54
VDQS	0.80	1.00	0.52	0.39	0.73	0.47	0.71	0.21	0.82
AUTRE_VDQS	0.46	0.52	1.00	0.71	0.35	0.26	0.35	-0.03	0.17
PROVENCE	0.60	0.39	0.71	1.00	-0.06	0.60	-0.05	0.21	0.18
MUSCAT	0.60	0.73	0.35	-0.06	1.00	0.27	1.00	0.33	0.56
RHONE	0.84	0.47	0.26	0.60	0.27	1.00	0.27	0.80	0.15
AOC_FORT	0.60	0.71	0.35	-0.05	1.00	0.27	1.00	0.33	0.55
AUTRE_FORT	0.69	0.21	-0.03	0.21	0.33	0.80	0.33	1.00	-0.06
TRES_FORT	0.54	0.82	0.17	0.18	0.56	0.15	0.55	-0.06	1.00

```r
corr<-cor(d, method="pearson")
corrplot(corr, type="upper", order="hclust", tl.col="black", tl.srt=45)
```

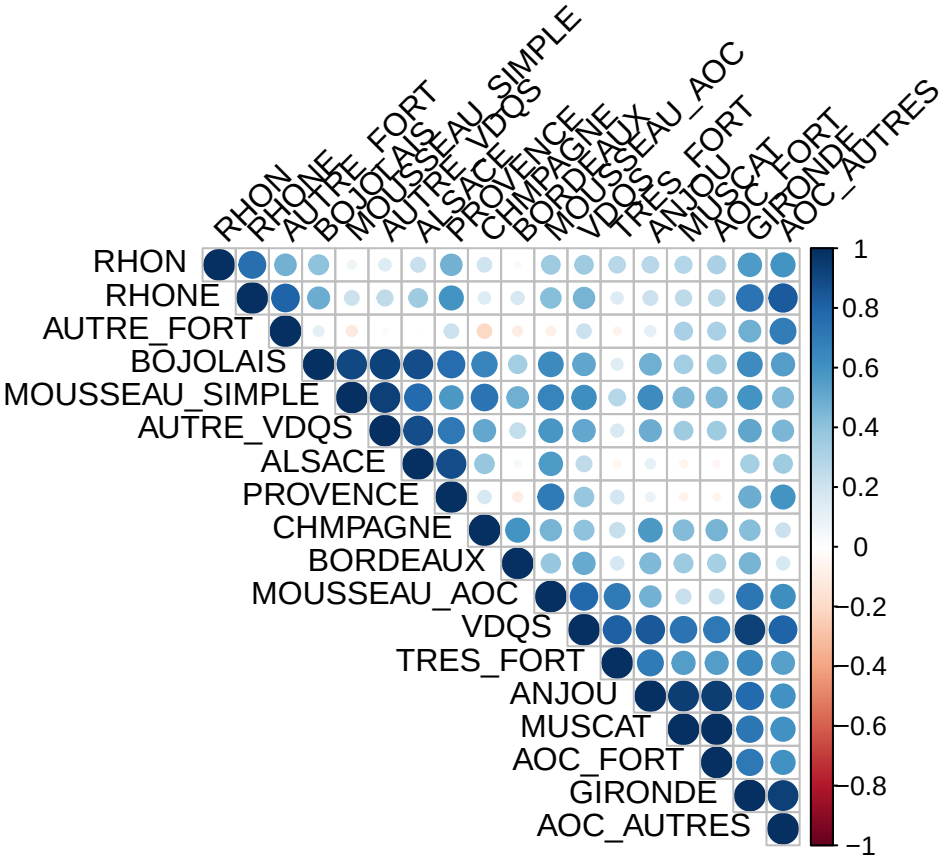

On caractérise ici une corrélation forte comme étant supérieure à 0.8, ou inférieure à -0.8. On a donc des fortes corrélations positives entre les variables

Var1	var2	Correlation
VDQS	TRES_FORT	0.82
ANJOU	AOC_FORT	0.95
RHONE	AOC_AUTRE	0.84
MUSCAT	AOC_FORT	1.00
ANJOU	MUSCAT	0.95
ALSACE	PROVENCE	0.89
AUTRE_VDQS	MOUSSEAU_SIMPLE	0.93
AUTRE_VDQS	ALSACE	0.88
AUTRE_VDQS	BOJOLAIS	0.93
GIRONDE	VDQS	0.93
ANJOU	VDQS	0.84
GIRONDE	AOC_AUTRE	0.93
MOUSSEAU_SIMPLE	BOJOLAIS	0.91
ALSACE	BOJOLAIS	0.89

Toutes les fortes corrélations sont positives, de plus, presque tout les coefficients de corrélation sont positifs. Ceci signifie que lorsqu'un pays consomme plus un type de vin qu'un autre pays, il a aura aussi un consommation supérieure sur les autres types de vin.

ACP

Choix du nombre de dimensions de l'ACP

Afin de réaliser une ACP sur les différents pays consommateurs de vin, on commence par calculer les valeurs propres des variables d'intérêt.

```
A = PCA(d, scale.unit=TRUE,graph=FALSE)
eig=A$eig

kable(eig, format="markdown")
```

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	8.8880543	49.378080	49.37808
comp 2	3.1963075	17.757264	67.13534
comp 3	2.7276039	15.153355	82.28870
comp 4	1.3266750	7.370416	89.65911
comp 5	0.9700696	5.389276	95.04839
comp 6	0.6845571	3.803095	98.85149
comp 7	0.2067326	1.148515	100.00000

Selon le critère de Kaiser, les 80% d'inertie totale sont atteints à partir de la 3ème dimension. Il y aurait donc 3 dimensions à garder pour faire notre ACP. Nous allons cependant afficher le graphique des valeurs propres pour valider cette hypothèse.

```
fviz_eig(A,choice = "eigenvalue", addlabels = TRUE )+
geom_hline (yintercept = 1, linetype = 2, color = "red")
```

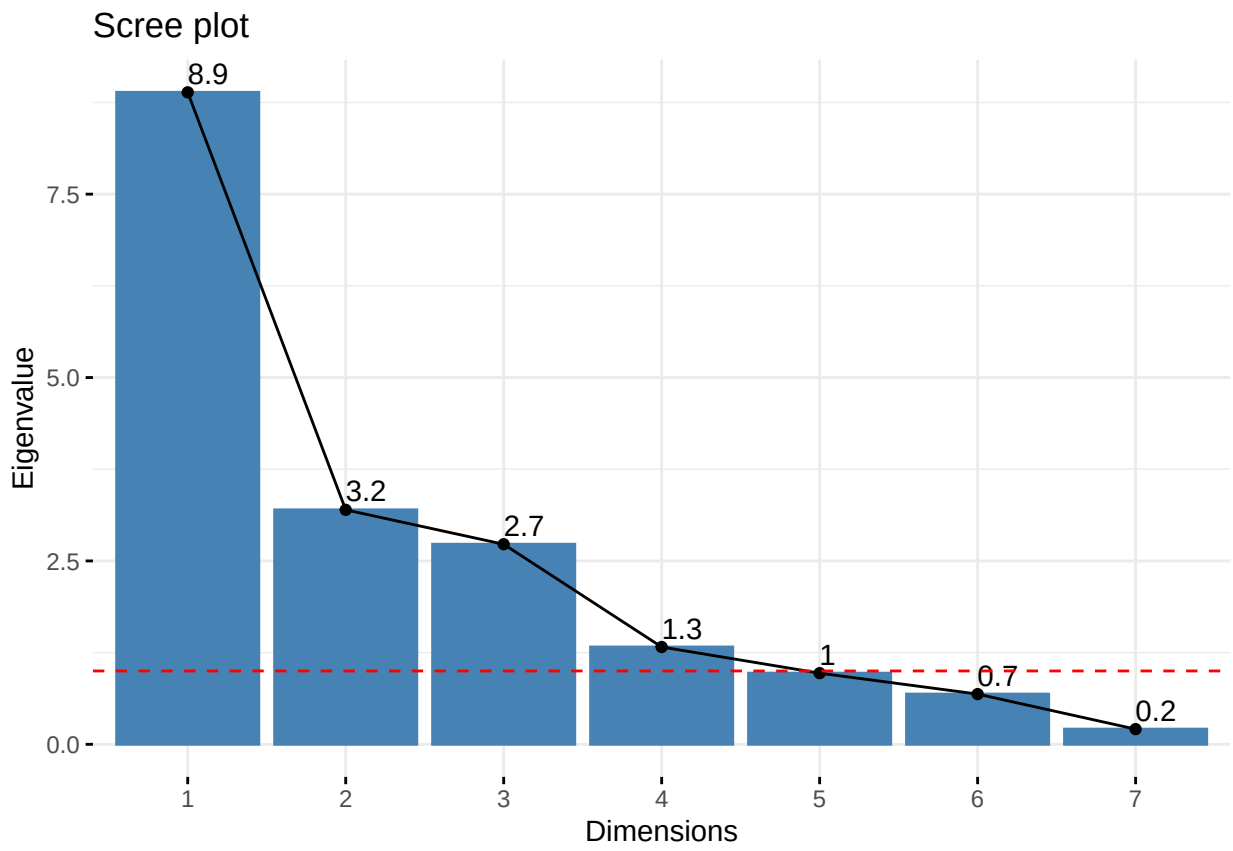

```
barplot(A$eig[,3]) +
lines(c(0,20),c(80,80),type = "l", lty=2,col="red")
```

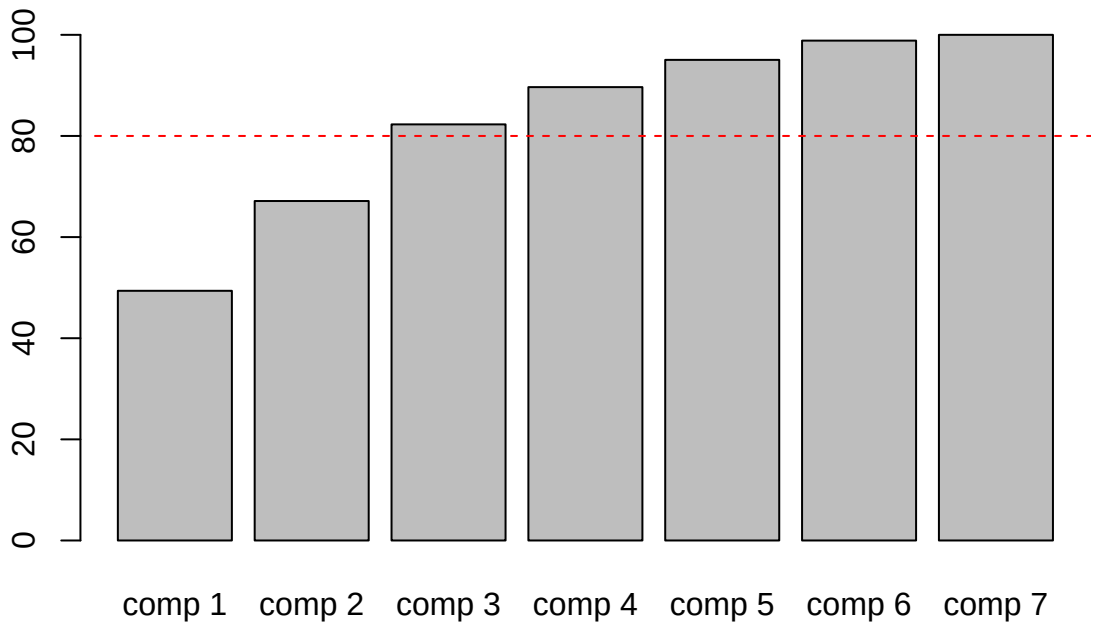


```
## numeric(0)
```

On ne retient pas le critère du coude, car cela nous ferait prendre 2 dimensions, qui ne seraient pas suffisantes pour retranscrire l'information. On ne retient pas non plus la méthode de Cattel, consistant à prendre 4 dimensions car il y a 4 valeurs propres supérieures ou égales à 1. En effet, il est préférable de garder un modèle simple en ne gardant que les axes utiles.

Nous allons donc prendre 3 axes, comme cela a été trouvé avec le pourcentage d'inertie.

Afficher les cordonnées, les corrélations, les cosinus carrés (qualité de la représentation) et les contributions de chaque variable (média publicitaire) par rapport aux cinq premières composantes principales.

```
kable(A$var$coord[,1:3], format="markdown", caption = "coord")
```

Table 6: coord

	Dim.1	Dim.2	Dim.3
CHMPAGNE	0.6072688	0.1024555	-0.5041422
MOUSSEAU_AOC	0.7775888	0.2470758	-0.0814971
MOUSSEAU_SIMPLE	0.8021424	0.3733386	-0.4236510
ALSACE	0.5591280	0.8134794	0.0078692
GIRONDE	0.9448574	-0.2172973	0.1820483

	Dim.1	Dim.2	Dim.3
BOJOLAIS	0.8234525	0.4984034	-0.0819653
BORDEAUX	0.4479770	-0.1548469	-0.4511489
RHON	0.5193233	-0.0518218	0.5809746
ANJOU	0.8057605	-0.4599190	-0.3146331
AOC_AUTRES	0.8500064	-0.1539469	0.4599846
VDQS	0.8948636	-0.2799860	-0.0775227
AUTRE_VDQS	0.7475147	0.5065459	-0.2339489
PROVENCE	0.6127968	0.6676495	0.3491175
MUSCAT	0.6967702	-0.6123740	-0.1569654
RHONE	0.6271885	0.0377170	0.7099313
AOC_FORT	0.6995089	-0.5985468	-0.1479583
AUTRE_FORT	0.3001127	-0.2669118	0.8028566
TRES_FORT	0.5935437	-0.4236271	-0.1342321

```
kable(A$var$cos2[,1:3], format="markdown", caption = "cos2")
```

Table 7: cos2

	Dim.1	Dim.2	Dim.3
CHMPAGNE	0.3687753	0.0104971	0.2541593
MOUSSEAU_AOC	0.6046444	0.0610465	0.0066418
MOUSSEAU_SIMPLE	0.6434325	0.1393817	0.1794802
ALSACE	0.3126241	0.6617487	0.0000619
GIRONDE	0.8927555	0.0472181	0.0331416
BOJOLAIS	0.6780740	0.2484060	0.0067183
BORDEAUX	0.2006834	0.0239776	0.2035353
RHON	0.2696967	0.0026855	0.3375315
ANJOU	0.6492500	0.2115255	0.0989940
AOC_AUTRES	0.7225110	0.0236996	0.2115859
VDQS	0.8007809	0.0783922	0.0060098
AUTRE_VDQS	0.5587782	0.2565887	0.0547321
PROVENCE	0.3755199	0.4457558	0.1218830
MUSCAT	0.4854887	0.3750019	0.0246381
RHONE	0.3933654	0.0014226	0.5040025
AOC_FORT	0.4893127	0.3582583	0.0218917
AUTRE_FORT	0.0900676	0.0712419	0.6445787
TRES_FORT	0.3522942	0.1794599	0.0180183

```
kable(A$var$contrib[,1:3], format="markdown", caption = "contrib")
```

Table 8: contrib

	Dim.1	Dim.2	Dim.3
CHMPAGNE	4.149112	0.3284142	9.3180435
MOUSSEAU_AOC	6.802888	1.9099057	0.2435024
MOUSSEAU_SIMPLE	7.239295	4.3607099	6.5801421
ALSACE	3.517351	20.7035354	0.0022703
GIRONDE	10.044443	1.4772708	1.2150433
BOJOLAIS	7.629049	7.7716548	0.2463081

	Dim.1	Dim.2	Dim.3
BORDEAUX	2.257900	0.7501644	7.4620561
RHON	3.034373	0.0840188	12.3746523
ANJOU	7.304749	6.6178071	3.6293383
AOC_AUTRES	8.129012	0.7414696	7.7572063
VDQS	9.009631	2.4525853	0.2203312
AUTRE_VDQS	6.286845	8.0276606	2.0066004
PROVENCE	4.224996	13.9459616	4.4685023
MUSCAT	5.462260	11.7323468	0.9032883
RHONE	4.425776	0.0445068	18.4778464
AOC_FORT	5.505284	11.2085054	0.8025964
AUTRE_FORT	1.013356	2.2288810	23.6316826
TRES_FORT	3.963681	5.6146018	0.6605896

Axe 1 : L'axe 1 de l'ACP révèle une forte contributions de vins de Gironde, des VDQS et des vins AOC_AUTRES. Ces trois variables sont aussi les mieux représentées sur les axes, puisque ce sont celles ayant le cos2 le plus élevé. De plus, toutes les coordonnées sont positives, entrainant un effet taille sur les données. Ceci signifie que lorqu'un pays consomme beaucoup ces trois types de vins, il aura tendance à beaucoup consommer les autres types de vins.

Axe2 : On remarque une forte contribution des vins d'Alsace, de Provence, du Muscat et des vins AOC_FORT sur l'axe 2. En revanche, les variables les mieux représentées sur cette dimension sont les vins d'Alsace et de Provence. De plus, cette dimension met en opposion les vins d'Alsace et de Provence, ayant des coordonnées positives, au Muscat, ayant une coordonnée négative. Cet axe oppose donc les pays consommant beaucoup de vin d'Alsace et de Provence aux pays consommant beaucoup de Muscat.

Axe3: Sur l'axe 3, on remarque une forte contribution des vins du Rhone, de Rhon et des vins AUTRE_FORT. Cependant, seuls les variables AUTRE_FORT et Rhone ont un cos2 élevé, entrainant une meilleure représentativité. Enfin, les coordonnées associées à ces 3 variables sont positives, ce qui signifie que si un pays consomme beaucoup un de ces 3 types de vin, il aura tendance à beaucoup consommer les 2 autres.

Représentation des types de vins (cercle des corrélations) par rapport aux composantes principales 1 et 2 et analyser le graphique

```
plot.PCA(A, axes=c(1,2), choix="var")
```

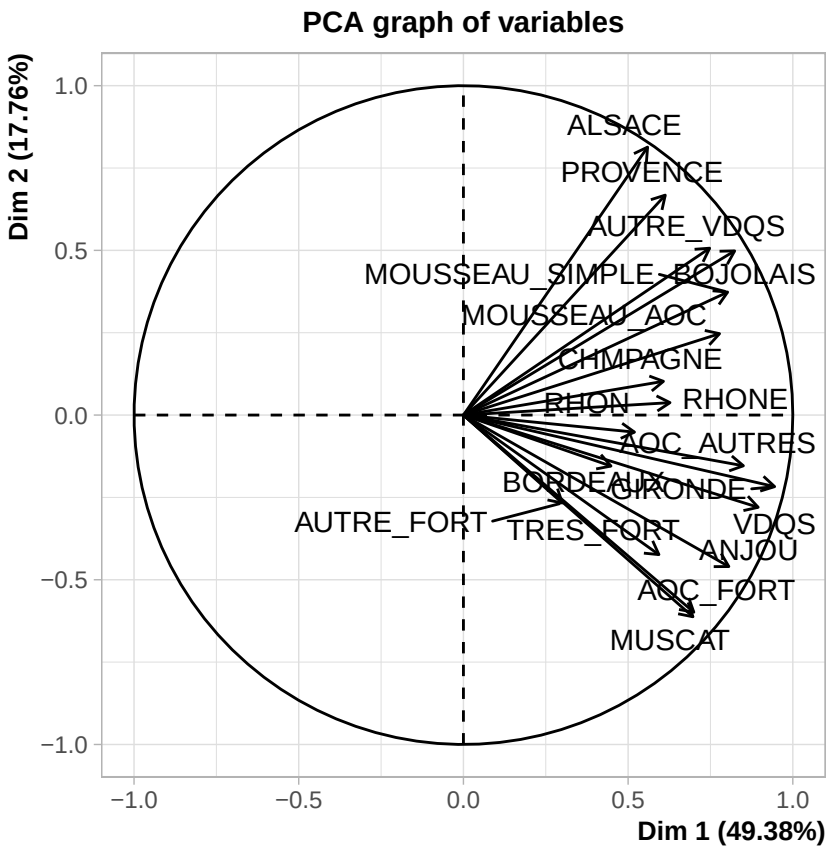

Comme dit précédemment, toutes les coordonnées ont une coordonée positive sur l'axe 1, entrainant un effet taille important. Tandis que la dimension 22 oppose bien les pays consommant beaucoup de vin d'Alsace et de Provence aux pays consommant beaucoup de Muscat et de vin AOC_Fles pays consommant beaucoup de vin d'Alsace et de Provence aux pays consommant beaucoup de Muscat et d'AOC_FORT.

Représentation des types de vins (cercle des corrélations) par rapport aux composantes principales 1 et 3 et analyser le graphique

```
plot.PCA(A, axes=c(1,3), choix="var")
```

```
## Warning: ggrepel: 4 unlabeled data points (too many overlaps). Consider
## increasing max.overlaps
```

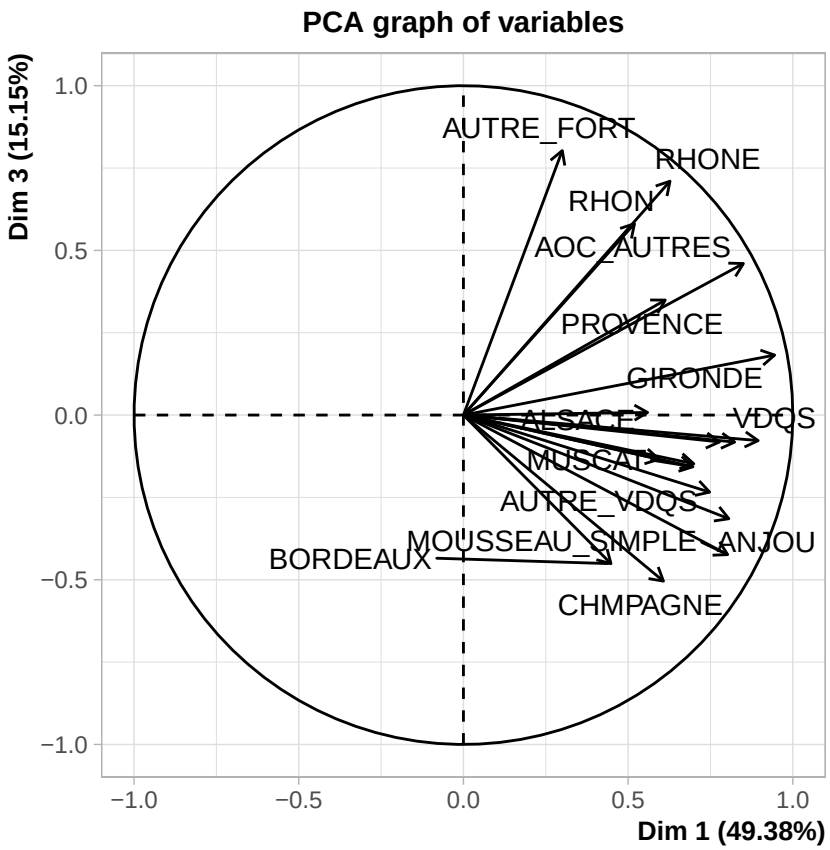

Ici, on remarque que comme dit précédement, les vins du Rhone, de Rhon et des vins AUTRE_FORT sont les mieux représentés sur la dimension 3. Dans une certaine mesure, ces vins peuvent être opposé au CHMPAGNE qui a une coordonnée négative élevée sur la dimension 3.

Représentation de la répartition des pays par rapport aux composantes principales 1 et 2 et analyser le graphique

```
plot.PCA(A, axes=c(1,2), choix="ind")
```

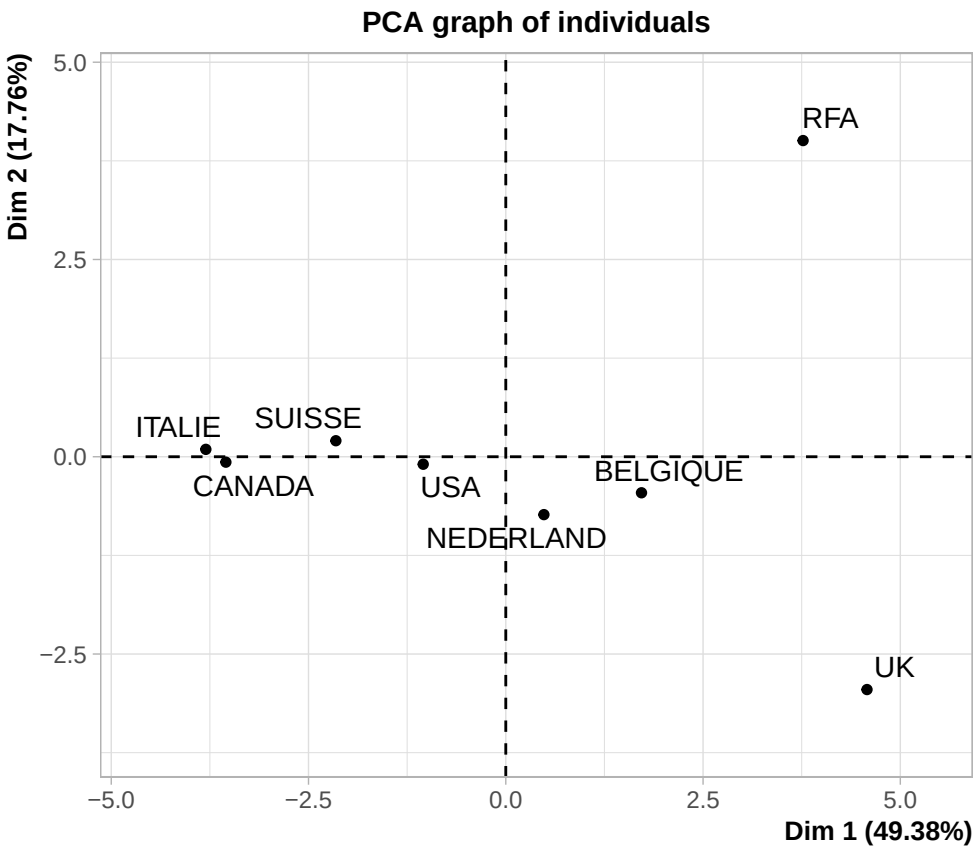

Interprétation:

Axe 1 : L'axe 1 oppose les pays UK et RFA à l'Italie, le Canada et la Suisse. On peut donc penser que, compte tenu de l'effet taille observé auparavant, cet axe oppose les pays consommant beaucoup de vins tels que UK et RFA aux pays en consommant peu tels que l'Italie, le Canada et la Suisse.

Axe2 : L'axe 2 oppose UK à RFA, tous les autres pays sont proches de 0 sur cette dimension. Ceci signifie que la RFA consomme beaucoup de vins d'Alsace et de Provence, tandis que UK consomme plutot du muscat

Représentation de la répartition des pays par rapport aux composantes principales 1 et 3 et analyser le graphique

```
plot.PCA(A, axes=c(1,3), choix="ind")
```

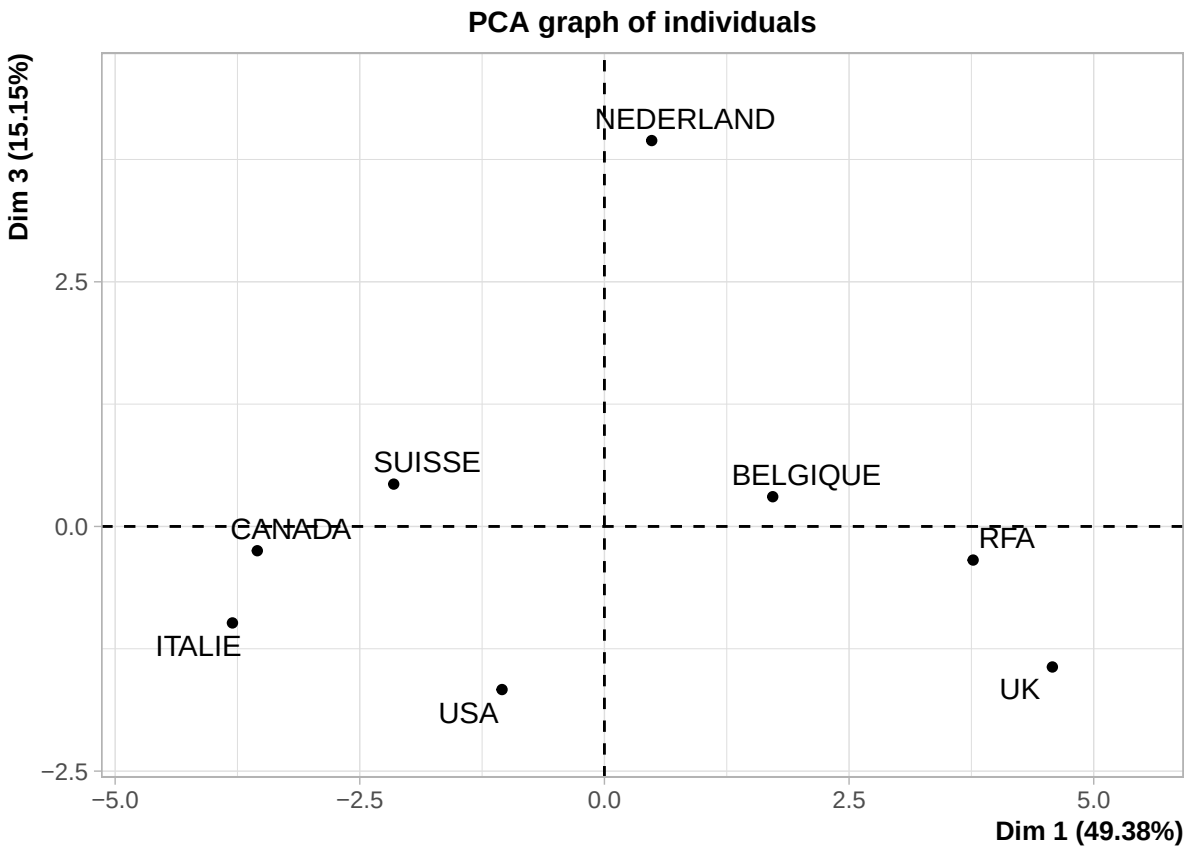

Interprétation:

Axe 1 : Comme dit précédement, l'axe 1 oppose majoritairement les pays consommant beaucoup de vins (UK et RFA) à ceux en consommant peu (Italie, Suisse et Canada).

Axe 3 : Sur l'axe 3, on remarque notamment que Nederland a une coordonnée très élevée sur cette dimension. Ceci signifie que ce pays consomme beaucoup de vin du Rhone, de Rhon et des vins AUTRE_FORT. Ce pays s'oppose à UK et USA, qui consommeraient peu de ces 3 vins.

III Classification des pays

Afin de classifier les pays, plusieurs méthodes peuvent être utilisées.

Classification ascendante hierarchique

La Classification Ascendante Hiérarchique (CAH) est une méthode de clustering qui regroupe les données en fonction de leur similarité, formant une hiérarchie de clusters. Elle commence en considérant chaque observation comme un cluster individuel puis fusionne progressivement les clusters les plus similaires jusqu'à ce qu'un seul cluster global soit obtenu.

Dans un premier temps nous allons chercher le nombre de cluster à utiliser.

```
CAH=HCPC(A, nb.clust=-1, graph=FALSE)
CAH$data.clust$clust
```

```
## [1] 2 2 3 1 4 1 1 1
## Levels: 1 2 3 4
```

```r
plot(CAH, choice="bar")
```

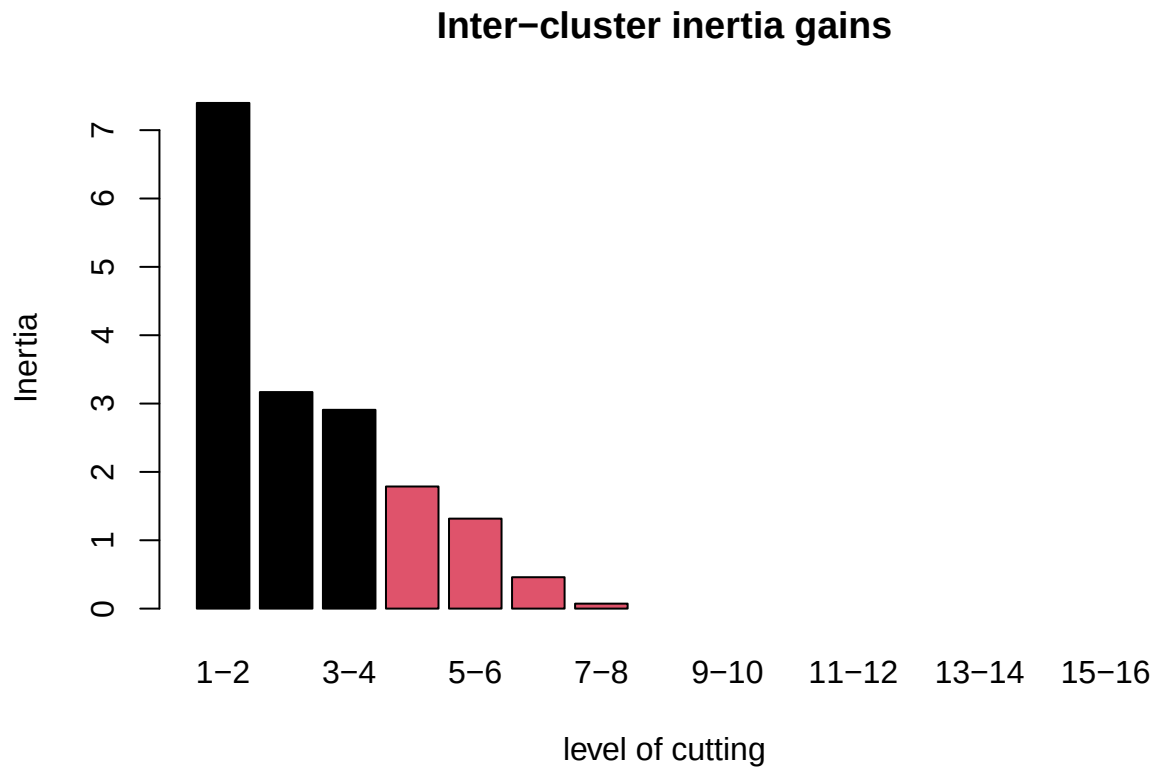


```r
plot(CAH, choice="tree")
```

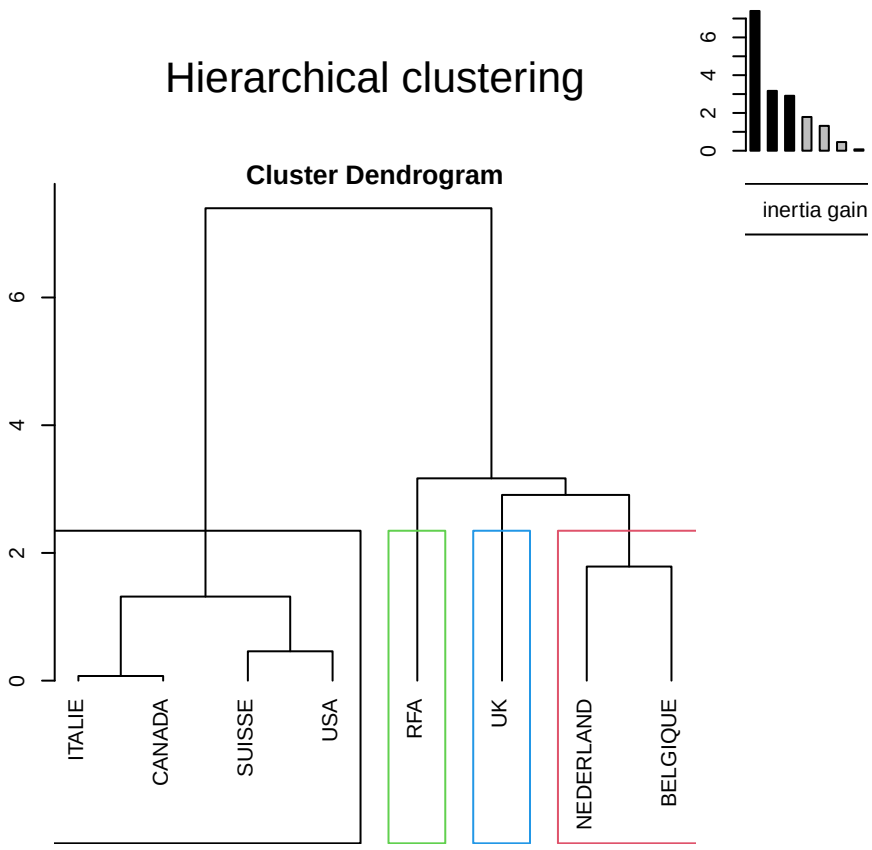

On observe avec les diagrammes en bar et en arbre, qu'ici nous pouvons utiliser **4 clusters**.

Caractériser chaque classe à l'aide des composantes principales utilisées

```
CAH$desc.axes
```

```
##
## Link between the cluster variable and the quantitative variables
## ================================================================
##            Eta2      P-value
## Dim.2 0.9961834 2.727729e-05
## Dim.1 0.9196585 1.177350e-02
##
## Description of each cluster by quantitative variables
## =====================================================
## $`1`
##          v.test Mean in category Overall mean sd in category Overall sd
## Dim.1 -2.340252        -2.637042 3.538836e-16        1.11217   2.981284
##          p.value
## Dim.1 0.01927072
##
## $`2`
##         v.test Mean in category Overall mean sd in category Overall sd
## Dim.3 1.964184         2.123658 6.106227e-16       1.819675   1.651546
##          p.value
## Dim.3 0.04950871
```

```
##
## $`3`
##         v.test Mean in category  Overall mean sd in category Overall sd p.value
## Dim.2 2.241248         4.006953 -1.960238e-16              0   1.787822 0.02501
##
## $`4`
## NULL
```

```
plot(CAH, choice="map", draw.tree = F)
```

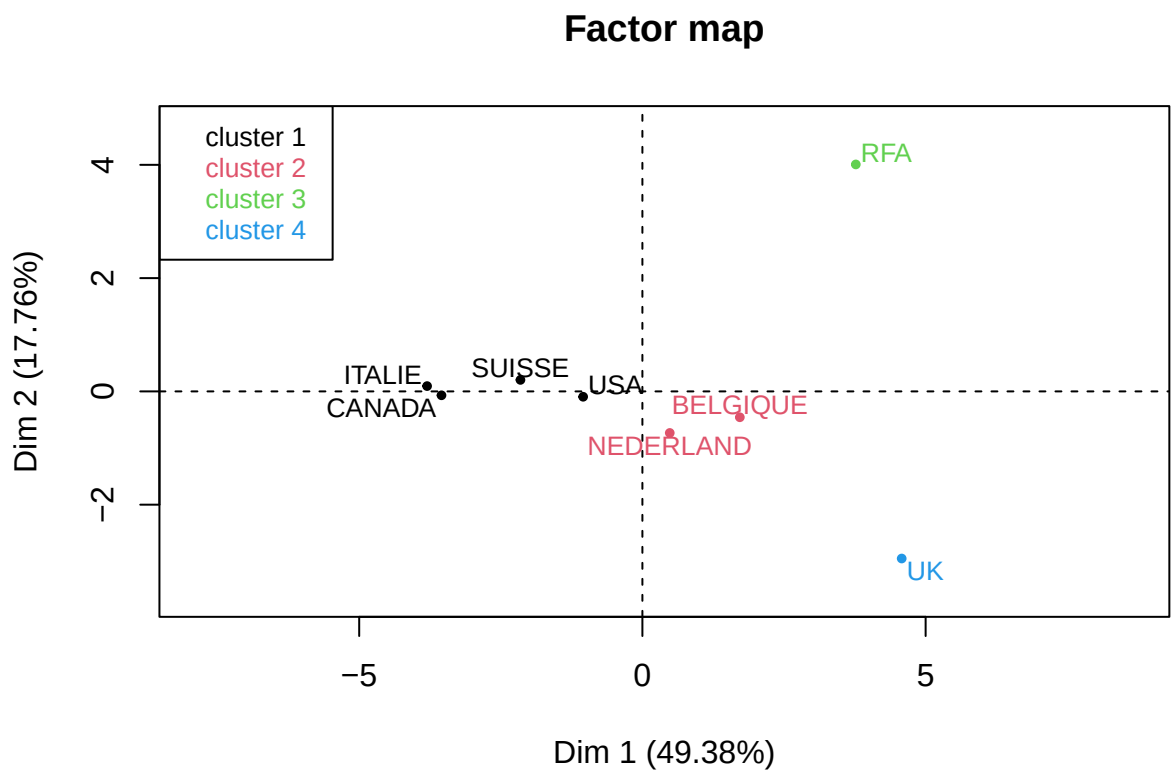


```
CAH$desc.var
```

```
##
## Link between the cluster variable and the quantitative variables
## ================================================================
##                       Eta2      P-value
## ALSACE           0.9989314 2.140176e-06
## AOC_FORT         0.9963153 2.542500e-05
## MUSCAT           0.9933236 8.339130e-05
## PROVENCE         0.9744164 1.216712e-03
## AUTRE_VDQS       0.9624343 2.612601e-03
## AOC_AUTRES       0.9619758 2.676346e-03
## ANJOU            0.9459293 5.381998e-03
## BOJOLAIS         0.9385901 6.924512e-03
## GIRONDE          0.8851958 2.374546e-02
## MOUSSEAU_SIMPLE 0.8741104 2.843738e-02
##
```

```
## Description of each cluster by quantitative variables
## ======================================================
## $`1`
##               v.test Mean in category Overall mean sd in category Overall sd
## RHONE      -2.000474           306.50      680.375       288.4029   494.4729
## VDQS       -2.151191           429.00     1040.625       380.8668   752.2380
## GIRONDE    -2.402317          5790.25    14922.250      4810.8704 10057.3751
## AOC_AUTRES -2.569393          1572.25    10284.750      1480.6969  8971.4211
##               p.value
## RHONE      0.04544910
## VDQS       0.03146112
## GIRONDE    0.01629159
## AOC_AUTRES 0.01018768
##
## $`2`
## NULL
##
## $`3`
##                   v.test Mean in category Overall mean sd in category
## ALSACE          2.617373            17183     3004.625              0
## AUTRE_VDQS      2.318720           191140    52982.750              0
## BOJOLAIS        2.279701            72977    23715.625              0
## PROVENCE        2.156399             2514      746.125              0
## MOUSSEAU_SIMPLE 2.028906            10439     3331.500              0
##                 Overall sd     p.value
## ALSACE           5417.0255 0.008860952
## AUTRE_VDQS      59583.4252 0.020410250
## BOJOLAIS        21608.6970 0.022625409
## PROVENCE          819.8273 0.031052508
## MOUSSEAU_SIMPLE  3503.1199 0.042467894
##
## $`4`
##            v.test Mean in category Overall mean sd in category Overall sd
## AOC_FORT 2.576845             1177      219.875              0   371.4328
## MUSCAT   2.572355            12891     2591.375              0  4003.9673
## ANJOU    2.452823             7582     1752.000              0  2376.8534
##              p.value
## AOC_FORT 0.009970655
## MUSCAT   0.010100929
## ANJOU    0.014174017
```

- Les valeurs d'Eta2 indiquent la force de la relation entre chaque catégorie de vin et les variables quantitatives. Une valeur proche de 1 indique une forte association.
- Les p-valeurs indiquent si la relation est significative. Des p-valeurs faibles (inférieures à 0,05) indiquent une relation significative.

Ici, il y à une forte association entre les variables quantitatives et les différentes catégories des lusters, de même, les différentes relations sont significatives.

On retrouve comme classification:

- **Cluster 1** : Ce cluster comprend les pays: Italie, Suisse, Canada et USA, et a des moyennes plus basses pour les catégories de vin RHONE, VDQS, GIRONDE et AOC_AUTRES par rapport à la moyenne globale.
- **Cluster 2** : Ce cluster comprend les pays: Pays-Bas et la Belgique
- **Cluster 3** : Ce cluster comprend le pays: RFA et à des moyennes plus élevées pour les catégories de

vin ALSACE, AUTRE_VDQS, BOJOLAIS, PROVENCE et MOUSSEAU_SIMPLE par rapport a la moyenne globale.

- **Cluster 4** : Ce cluster comprend le pays: UK et a des moyennes plus élevées pour les catégories de vin AOC_FORT, MUSCAT et ANJOU par rapport à la moyenne globale.

K-means

```
distance <- get_dist(d)
fviz_dist(distance, gradient = list(low = "#00AFBB", mid = "white", high = "#FC4E07"))
```

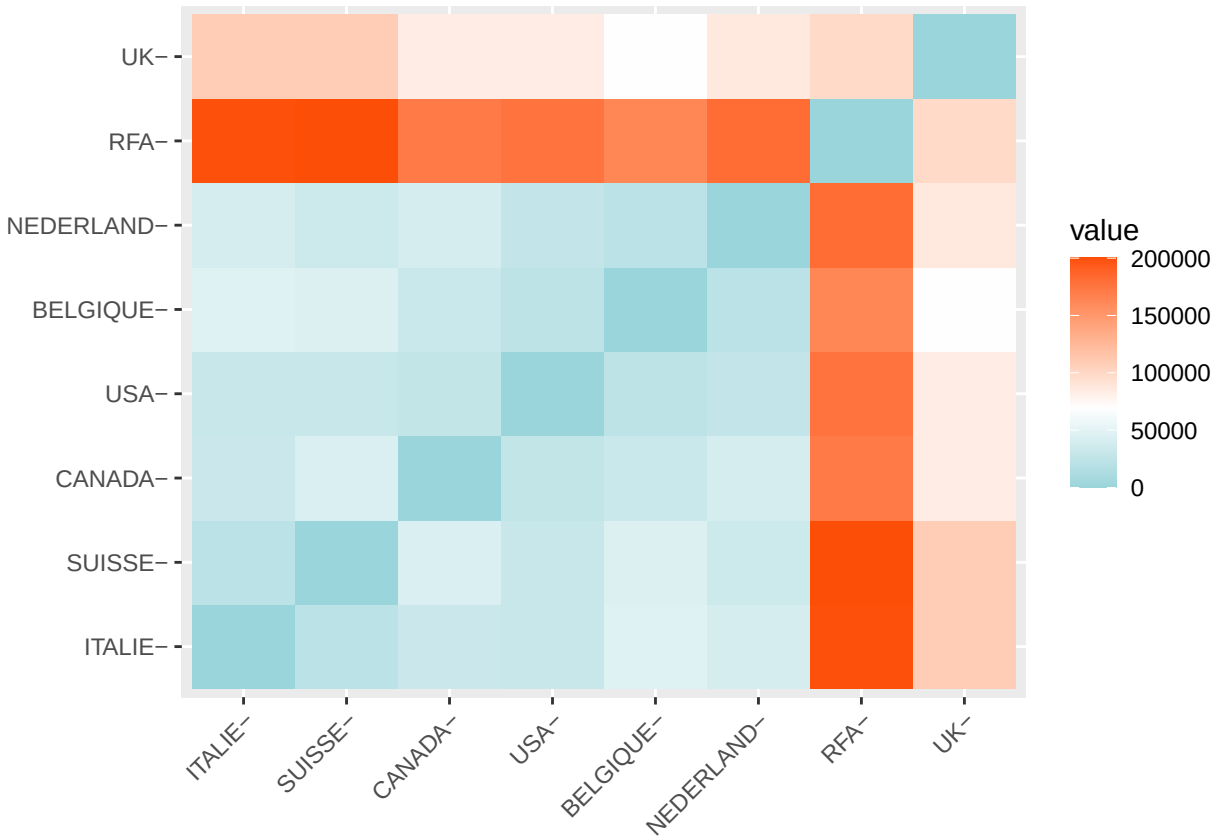


```
# 2. Choix du nombre de clusters (K) - Exemple avec la méthode du coude
wss <- numeric(7)  # Pour stocker la somme des carrés des distances
for (i in 1:7) {
  wss[i] <- sum(kmeans(d, centers = i)$withinss)
}
plot(1:7, wss, type = "b", xlab = "Number of Clusters",
     ylab = "Within groups sum of squares")
```

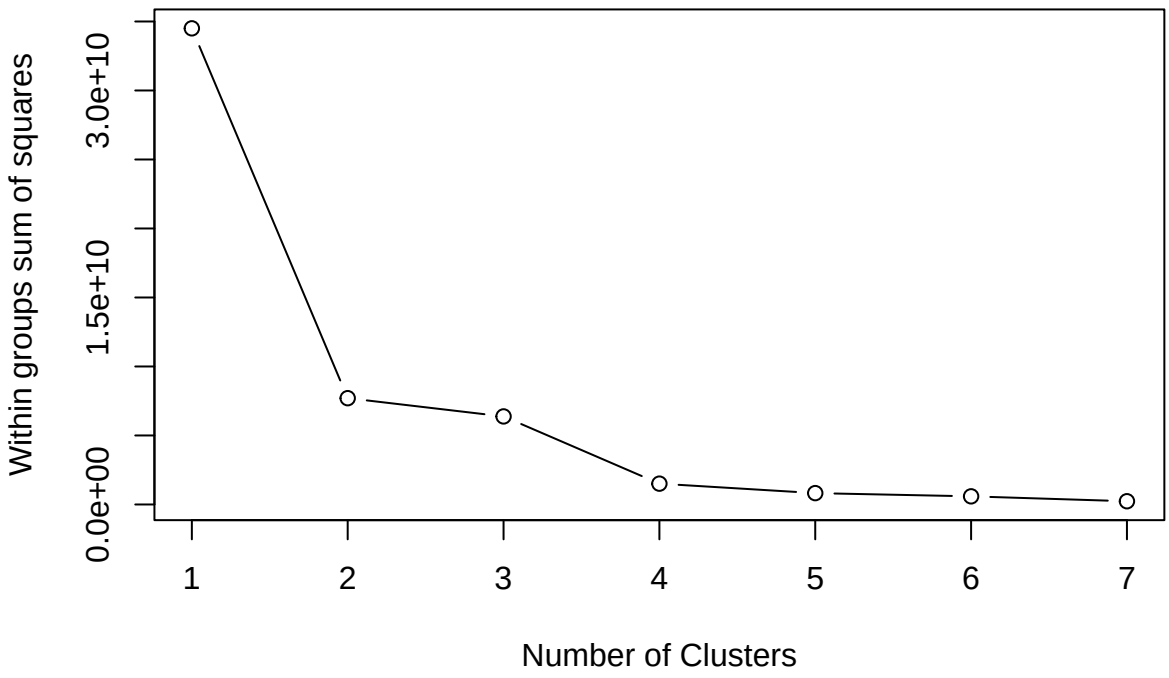


```
library(metan)
```

```
## Registered S3 method overwritten by 'GGally':
##   method from
##   +.gg   ggplot2
## |=========================================================|
## | Multi-Environment Trial Analysis (metan) v1.18.0        |
## | Author: Tiago Olivoto                                   |
## | Type 'citation('metan')' to know how to cite metan      |
## | Type 'vignette('metan_start')' for a short tutorial     |
## | Visit 'https://bit.ly/pkgmetan' for a complete tutorial |
## |=========================================================|
##
## Attachement du package : 'metan'
## L'objet suivant est masqué depuis 'package:factoextra':
##
##     get_dist
```

```
k2 <- kmeans(d, centers = 2, nstart = 25)
```

```
dprime=d
nom=rownames(d)
dprime$clust=CAH$data.clust$clust
```

```r
dprime$clust=as.factor(dprime$clust)
dt=rpart(clust~., data=dprime, minsplit=1)
plot(dt)
text(dt,pretty=0,cex=0.8)
```

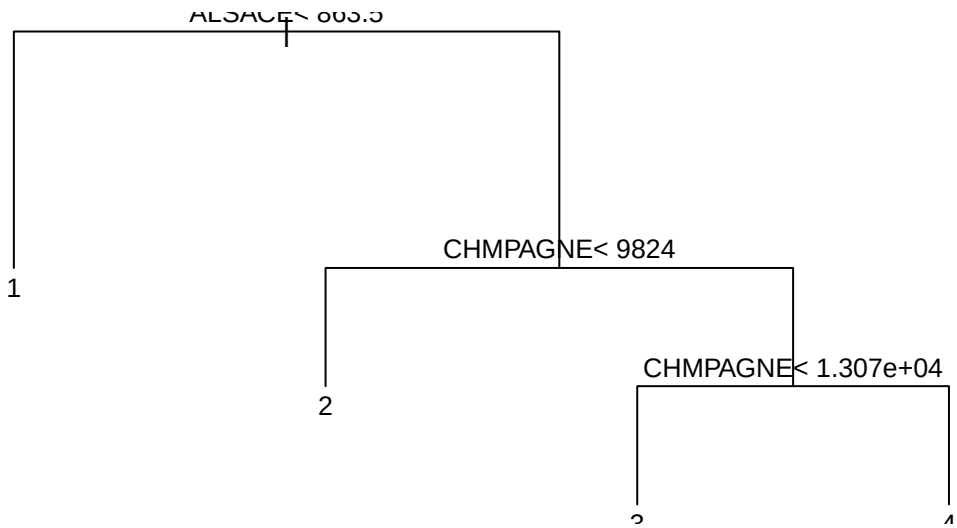


```r
dt
```

```
## n= 8
##
## node), split, n, loss, yval, (yprob)
##       * denotes terminal node
##
##  1) root 8 4 1 (0.5000000 0.2500000 0.1250000 0.1250000)
##    2) ALSACE< 863.5 4 0 1 (1.0000000 0.0000000 0.0000000 0.0000000) *
##    3) ALSACE>=863.5 4 2 2 (0.0000000 0.5000000 0.2500000 0.2500000)
##      6) CHMPAGNE< 9823.5 2 0 2 (0.0000000 1.0000000 0.0000000 0.0000000) *
##      7) CHMPAGNE>=9823.5 2 1 3 (0.0000000 0.0000000 0.5000000 0.5000000)
##       14) CHMPAGNE< 13067 1 0 3 (0.0000000 0.0000000 1.0000000 0.0000000) *
##       15) CHMPAGNE>=13067 1 0 4 (0.0000000 0.0000000 0.0000000 1.0000000) *
```

```r
res.km <- kmeans(d, 4, nstart = 25)
fviz_cluster(res.km, data = d,
             palette = c("#2E9FDF", "#00AFBB", "#E7B800", "#E1C800"),
             geom = "point",
             ellipse.type = "convex",
             ggtheme = theme_bw()
             )
```

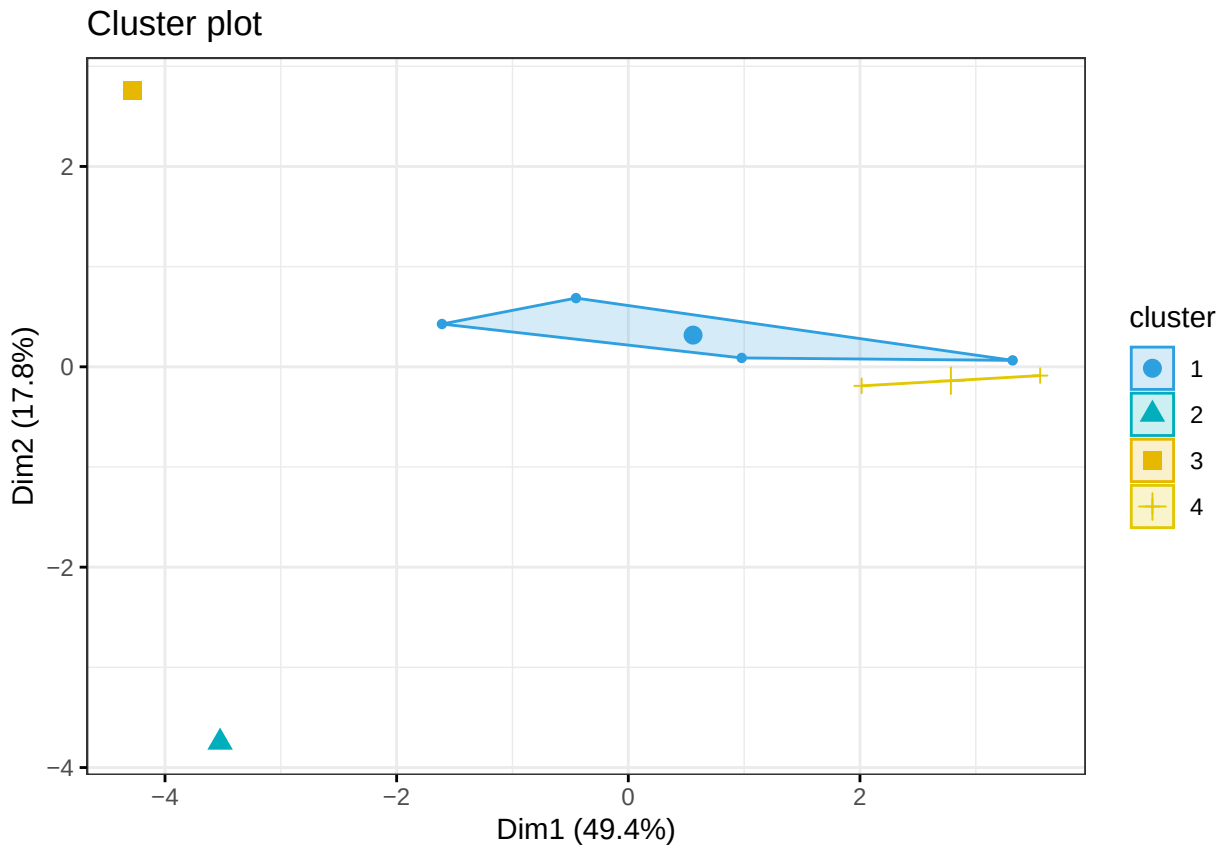


```
res.km <- kmeans(d, 3, nstart = 25)
fviz_cluster(res.km, data = d,
             palette = c("#2E9FDF", "#00AFBB", "#E7B800", "#E1C800"),
             geom = "point",
             ellipse.type = "convex",
             ggtheme = theme_bw()
             )
```

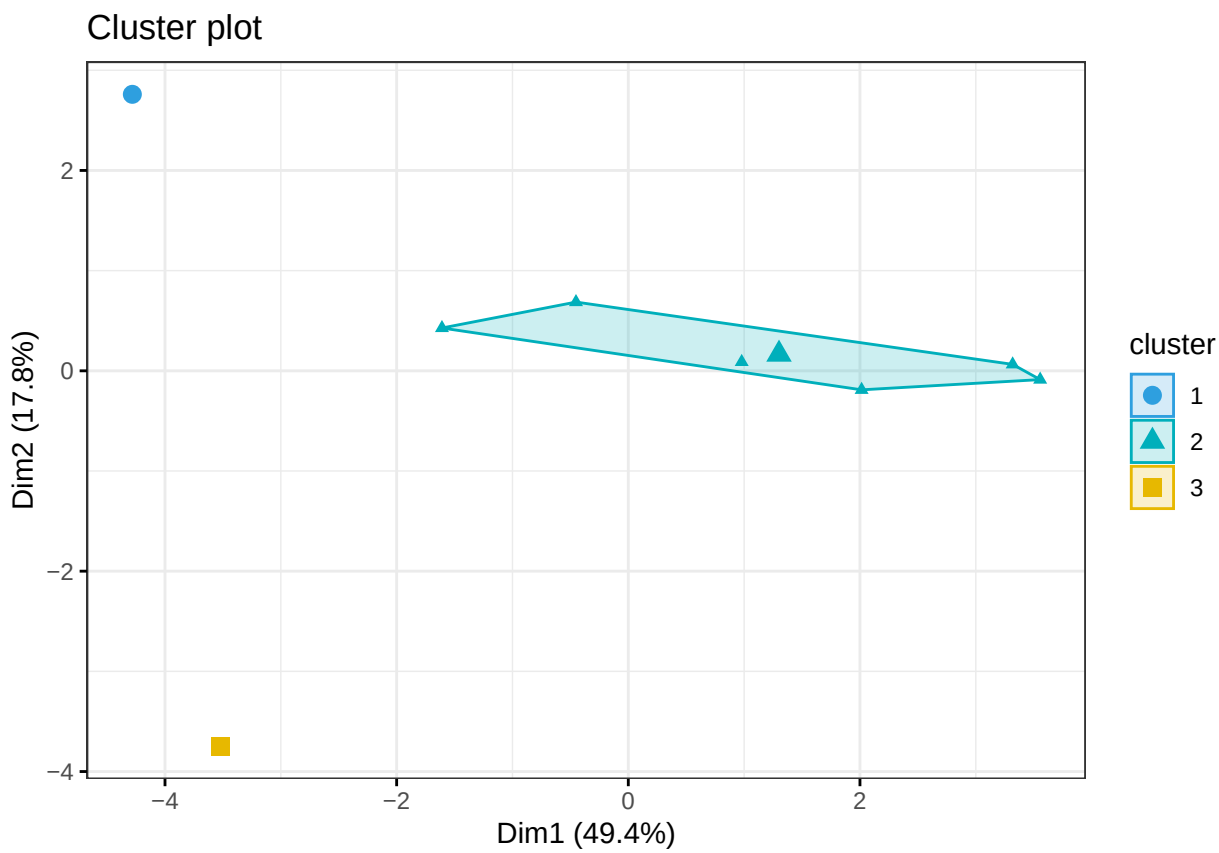


```
dprime[,19]=as.integer(dprime[,19])

dprime[,-19]=scale(dprime[,-19])

m1 = lm(clust~., data=dprime)
summary(m1)
```

```
##
## Call:
## lm(formula = clust ~ ., data = dprime)
##
## Residuals:
## ALL 8 residuals are 0: no residual degrees of freedom!
##
## Coefficients: (11 not defined because of singularities)
##                  Estimate Std. Error t value Pr(>|t|)
## (Intercept)        1.8750        NaN     NaN      NaN
## CHMPAGNE          -0.1718        NaN     NaN      NaN
## MOUSSEAU_AOC      -0.1076        NaN     NaN      NaN
## MOUSSEAU_SIMPLE    0.9578        NaN     NaN      NaN
## ALSACE            -1.1654        NaN     NaN      NaN
## GIRONDE            0.5428        NaN     NaN      NaN
## BOJOLAIS           1.0372        NaN     NaN      NaN
## BORDEAUX          -0.5436        NaN     NaN      NaN
## RHON                   NA         NA      NA       NA
## ANJOU                  NA         NA      NA       NA
```

```
## AOC_AUTRES            NA         NA      NA       NA
## VDQS                  NA         NA      NA       NA
## AUTRE_VDQS            NA         NA      NA       NA
## PROVENCE              NA         NA      NA       NA
## MUSCAT                NA         NA      NA       NA
## RHONE                 NA         NA      NA       NA
## AOC_FORT              NA         NA      NA       NA
## AUTRE_FORT            NA         NA      NA       NA
## TRES_FORT             NA         NA      NA       NA
##
## Residual standard error: NaN on 0 degrees of freedom
## Multiple R-squared:      1,  Adjusted R-squared:    NaN
## F-statistic:   NaN on 7 and 0 DF,  p-value: NA
```

```
choix = regsubsets(clust~., int= T, nbest = 1, nvmax=7, method="exh", data = dprime)
```

```
## Warning in leaps.setup(x, y, wt = wt, nbest = nbest, nvmax = nvmax, force.in =
## force.in, : 11 linear dependencies found
```

```
res = summary(choix)
```

```
## Warning in log(vr): Production de NaN
```

```
print(res)
```

```
## Subset selection object
## Call: regsubsets.formula(clust ~ ., int = T, nbest = 1, nvmax = 7,
##     method = "exh", data = dprime)
## 18 Variables  (and intercept)
##                 Forced in Forced out
## CHMPAGNE            FALSE      FALSE
## MOUSSEAU_AOC        FALSE      FALSE
## MOUSSEAU_SIMPLE     FALSE      FALSE
## ALSACE              FALSE      FALSE
## GIRONDE             FALSE      FALSE
## BOJOLAIS            FALSE      FALSE
## BORDEAUX            FALSE      FALSE
## RHON                FALSE      FALSE
## ANJOU               FALSE      FALSE
## AOC_AUTRES          FALSE      FALSE
## VDQS                FALSE      FALSE
## AUTRE_VDQS          FALSE      FALSE
## PROVENCE            FALSE      FALSE
## MUSCAT              FALSE      FALSE
## RHONE               FALSE      FALSE
## AOC_FORT            FALSE      FALSE
## AUTRE_FORT          FALSE      FALSE
## TRES_FORT           FALSE      FALSE
## 1 subsets of each size up to 7
## Selection Algorithm: exhaustive
##          CHMPAGNE MOUSSEAU_AOC MOUSSEAU_SIMPLE ALSACE GIRONDE BOJOLAIS BORDEAUX
## 1  ( 1 ) " "      " "          " "              " "    " "     " "      " "
## 2  ( 1 ) " "      " "          " "              " "    " "     " "      " "
## 3  ( 1 ) " "      " "          "*"              " "    " "     " "      " "
## 4  ( 1 ) " "      " "          " "              " "    " "     "*"      " "
## 5  ( 1 ) " "      " "          " "              "*"    " "     " "      "*"
```

```
## 6  ( 1 ) " "       " "           " "              "*"     " "      " "       " "
## 7  ( 1 ) "*"       "*"           "*"              "*"     "*"      "*"       " "
##          RHON ANJOU AOC_AUTRES VDQS AUTRE_VDQS PROVENCE MUSCAT RHONE AOC_FORT
## 1  ( 1 ) " "  "*"   " "         " "  " "        " "      " "    " "   " "
## 2  ( 1 ) " "  " "   " "         " "  " "        "*"      " "    " "   "*"
## 3  ( 1 ) " "  " "   " "         " "  " "        "*"      " "    " "   "*"
## 4  ( 1 ) "*"  " "   " "         " "  " "        "*"      " "    " "   "*"
## 5  ( 1 ) " "  "*"   " "         "*"  " "        " "      " "    " "   " "
## 6  ( 1 ) "*"  " "   " "         " "  " "        " "      " "    "*"   "*"
## 7  ( 1 ) " "  " "   " "         " "  " "        " "      " "    " "   " "
##          AUTRE_FORT TRES_FORT
## 1  ( 1 ) " "        " "
## 2  ( 1 ) " "        " "
## 3  ( 1 ) " "        " "
## 4  ( 1 ) " "        " "
## 5  ( 1 ) "*"        " "
## 6  ( 1 ) "*"        "*"
## 7  ( 1 ) "*"        " "
```

```
#choix du meilleur modèle selon le critère BIC
plot(choix, scale="bic")
```

```
## Warning in log(vr): Production de NaN
```

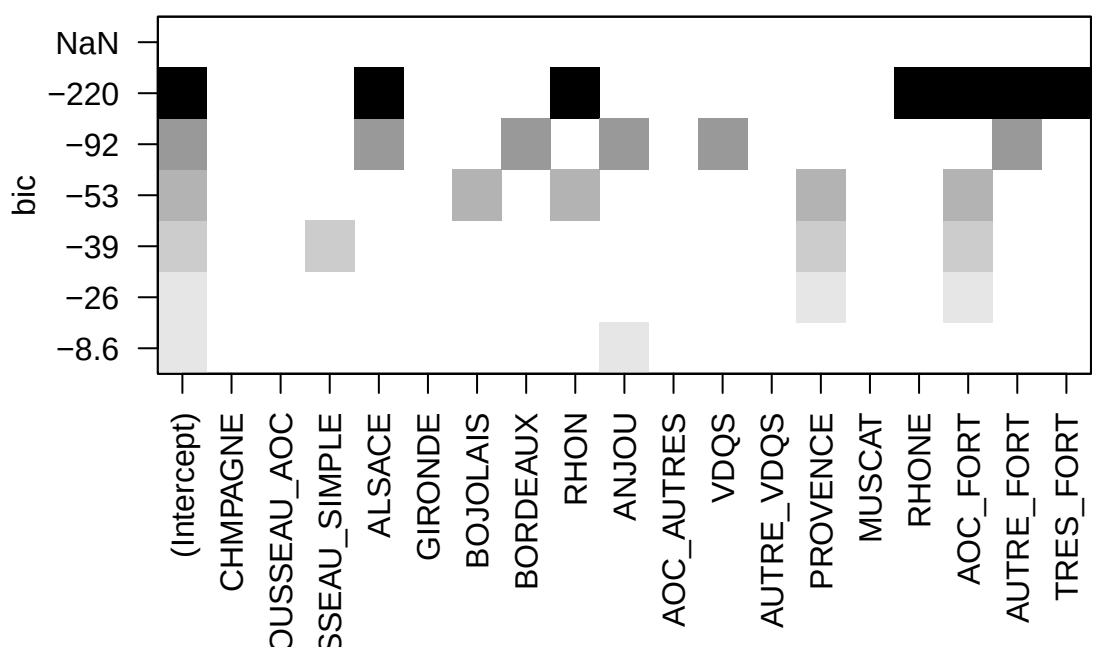


```
m1 = lm(clust~ALSACE+RHON+RHONE+AOC_FORT+AUTRE_FORT+TRES_FORT, data=dprime) # estime le modele linéaire
summary(m1)
```

```
##
```

```
## Call:
## lm(formula = clust ~ ALSACE + RHON + RHONE + AOC_FORT + AUTRE_FORT +
##     TRES_FORT, data = dprime)
##
## Residuals:
##   BELGIQUE  NEDERLAND        RFA     ITALIE         UK     SUISSE        USA
##  1.811e-08  2.258e-09  3.987e-09  6.555e-07 -9.446e-09  1.031e-07 -1.140e-07
##     CANADA
## -6.595e-07
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.875e+00  3.333e-07 5625335 1.13e-07 ***
## ALSACE       5.884e-01  5.130e-07 1146900 5.55e-07 ***
## RHON        -2.084e-02  6.338e-07  -32881 1.94e-05 ***
## RHONE       -3.279e-02  1.227e-06  -26727 2.38e-05 ***
## AOC_FORT     8.413e-01  5.142e-07 1636193 3.89e-07 ***
## AUTRE_FORT   1.519e-01  9.663e-07  157219 4.05e-06 ***
## TRES_FORT    2.028e-01  5.285e-07  383665 1.66e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 9.428e-07 on 1 degrees of freedom
## Multiple R-squared:      1,  Adjusted R-squared:      1
## F-statistic: 1.664e+12 on 6 and 1 DF,  p-value: 5.934e-07
```

```
check_collinearity(m1)
```

```
## # Check for Multicollinearity
##
## Low Correlation
##
##       Term  VIF     VIF 95% CI Increased SE Tolerance Tolerance 95% CI
##     ALSACE 2.07 [ 2.07,  2.07]         1.44      0.48     [0.48, 0.48]
##       RHON 3.16 [ 3.16,  3.16]         1.78      0.32     [0.32, 0.32]
##   AOC_FORT 2.08 [ 2.08,  2.08]         1.44      0.48     [0.48, 0.48]
##  TRES_FORT 2.20 [ 2.20,  2.20]         1.48      0.45     [0.45, 0.45]
##
## Moderate Correlation
##
##        Term  VIF     VIF 95% CI Increased SE Tolerance Tolerance 95% CI
##  AUTRE_FORT 7.35 [ 7.35,  7.35]         2.71      0.14     [0.14, 0.14]
##
## High Correlation
##
##   Term   VIF     VIF 95% CI Increased SE Tolerance Tolerance 95% CI
##  RHONE 11.85 [11.85, 11.85]         3.44      0.08     [0.08, 0.08]
```

```
m2 <- update(m1, .~.-RHONE)
check_collinearity(m2)
```

```
## # Check for Multicollinearity
##
## Low Correlation
##
```

```
##        Term  VIF   VIF 95% CI Increased SE Tolerance Tolerance 95% CI
##      ALSACE 1.10 [1.04, 1.24]         1.05      0.91     [0.80, 0.96]
##        RHON 1.62 [1.47, 1.81]         1.27      0.62     [0.55, 0.68]
##    AOC_FORT 1.77 [1.60, 1.98]         1.33      0.57     [0.50, 0.63]
##  AUTRE_FORT 1.64 [1.49, 1.84]         1.28      0.61     [0.54, 0.67]
##   TRES_FORT 1.75 [1.59, 1.96]         1.32      0.57     [0.51, 0.63]
```

```r
summary(m2)
```

```
##
## Call:
## lm(formula = clust ~ ALSACE + RHON + AOC_FORT + AUTRE_FORT +
##     TRES_FORT, data = dprime)
##
## Residuals:
##   BELGIQUE  NEDERLAND        RFA     ITALIE         UK     SUISSE        USA
##  2.801e-06 -4.035e-05  2.863e-04  8.201e-03  3.330e-05  4.191e-04 -2.070e-02
##     CANADA
##  1.179e-02
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.875000   0.006299 297.654 1.13e-05 ***
## ALSACE       0.578984   0.007055  82.065 0.000148 ***
## RHON        -0.032689   0.008563  -3.818 0.062277 .
## AOC_FORT     0.846666   0.008951  94.585 0.000112 ***
## AUTRE_FORT   0.129165   0.008629  14.969 0.004433 **
## TRES_FORT    0.196393   0.008916  22.026 0.002055 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.01782 on 2 degrees of freedom
## Multiple R-squared:  0.9999, Adjusted R-squared:  0.9997
## F-statistic:  5591 on 5 and 2 DF,  p-value: 0.0001788
```

```r
m2 <- update(m2, .~.-RHON)
summary(m2)
```

```
##
## Call:
## lm(formula = clust ~ ALSACE + AOC_FORT + AUTRE_FORT + TRES_FORT,
##     data = dprime)
##
## Residuals:
##  BELGIQUE NEDERLAND       RFA    ITALIE        UK    SUISSE       USA    CANADA
## -0.001220 -0.000525  0.001793  0.034569  0.001140 -0.058153 -0.003419  0.025815
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.87500    0.01481 126.638 1.09e-06 ***
## ALSACE       0.57109    0.01585  36.023 4.70e-05 ***
## AOC_FORT     0.84682    0.02104  40.250 3.37e-05 ***
## AUTRE_FORT   0.11273    0.01758   6.413  0.00768 **
## TRES_FORT    0.18589    0.01994   9.325  0.00261 **
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.04188 on 3 degrees of freedom
## Multiple R-squared:  0.9994, Adjusted R-squared:  0.9986
## F-statistic:  1264 on 4 and 3 DF,  p-value: 3.607e-05
```

```
check_model(m2)
```

```
check_normality(m2)
```

```
## OK: residuals appear as normally distributed (p = 0.250).
```

```
check_heteroscedasticity(m2)
```

```
## OK: Error variance appears to be homoscedastic (p = 0.108).
```

DBSCAN

DBSCAN est un algorithme de clustering basé sur la densité qui identifie automatiquement les clusters dans les données sans avoir besoin de spécifier le nombre de clusters à l'avance. En utilisant deux paramètres principaux, Eps (epsilon) et MinPts, il peut détecter des clusters de formes arbitraires et est efficace pour gérer les données bruitées.

```
d_norm<-scale(d)

result1 <- dbscan(d_norm, eps = 4, minPts = 1)

result1
```

```
## DBSCAN clustering for 8 objects.
## Parameters: eps = 4, minPts = 1
## Using euclidean distances and borderpoints = TRUE
## The clustering contains 5 cluster(s) and 0 noise points.
##
## 1 2 3 4 5
## 1 1 1 4 1
##
## Available fields: cluster, eps, minPts, dist, borderPoints
```

```
result1$cluster
```

```
## [1] 1 2 3 4 5 4 4 4
```

```
d_norm<-scale(d)

result2 <- dbscan(d_norm, eps = 5, minPts = 1)

result2
```

```
## DBSCAN clustering for 8 objects.
## Parameters: eps = 5, minPts = 1
## Using euclidean distances and borderpoints = TRUE
## The clustering contains 3 cluster(s) and 0 noise points.
##
## 1 2 3
## 6 1 1
##
## Available fields: cluster, eps, minPts, dist, borderPoints
```

```
result2$cluster
```

```
## [1] 1 1 2 1 3 1 1 1
```

```
plot_eps4 <- fviz_cluster(result1, data = d,
                          palette = c("#2E9FDF", "#E1C890", "#E7B800", "#E1C800", "#00AFBB"),
                          geom = "point",
                          ellipse.type = "convex",
                          ggtheme = theme_bw(),
                          main = "DBSCAN avec eps=4"
)

# Plot pour eps=4
plot_eps5 <- fviz_cluster(result2, data = d,
                          palette = c("#2E9FDF", "#E1C890", "#E7B800", "#E1C800", "#00AFBB"),
                          geom = "point",
                          ellipse.type = "convex",
                          ggtheme = theme_bw(),
                          main = "DBSCAN avec eps=5"
)

# Affichage des deux plots
grid.arrange(plot_eps4, plot_eps5, ncol = 2)
```

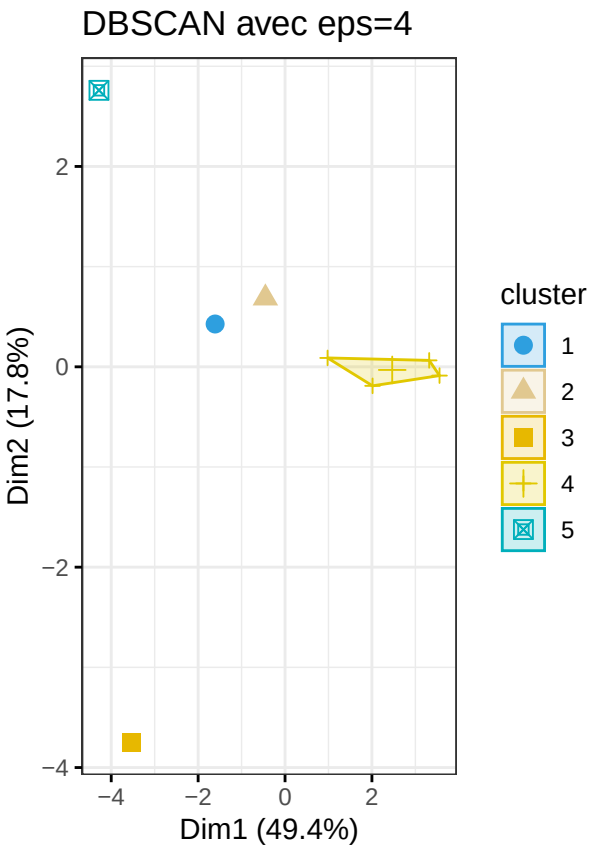

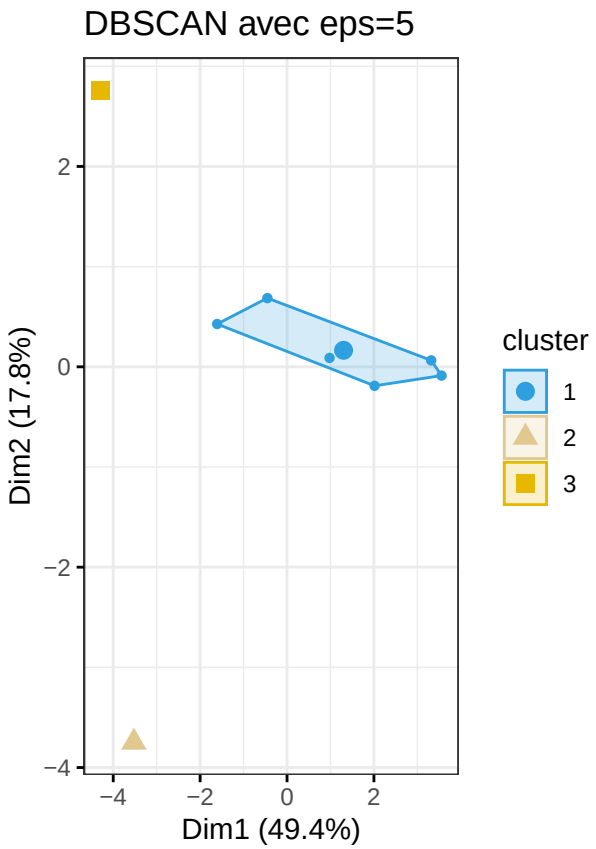

En utilisant les paramètres eps=4 et minPts=1, l'algorithme DBSCAN génère 5 clusters distincts. DBSCAN identifie les clusters en se basant sur la densité des points dans l'espace des données. Avec ces paramètres, nous observons cinq groupes de points qui sont considérés comme densément liés entre eux.

Dans le DBSCAN avec eps=4, on observe dans les clusters:

- **Cluster 1** : Belgique
- **Cluster 2** : Pays_Bas
- **Cluster 3** : RFA
- **Cluster 4** : Italie, Suisse, USA, Canada
- **Cluster 5** : UK

Comme vu avec la méthode de k-means il peut être intéressant de de regrouper les cluster 1 et 2 avec le 4 ème cluster qui ont des centres assez proches. Cependant ici on regarde les clsuter sur la 1ere et la 2eme dimension cela à aussi surment un impact.

En utilisant les paramètres eps=4 et minPts=1, l'algorithme DBSCAN génère 3 clusters distincts. DBSCAN identifie les clusters en se basant sur la densité des points dans l'espace des données. Avec ces paramètres, nous observons trois groupes de points qui sont considérés comme densément liés entre eux.

Dans le DBSCAN avec eps=5, on observe dans les clusters:

- **Cluster 1** : Belgique , Pays-Bas, Italie, Canada, Suisse, USA
- **Cluster 2** : RFA
- **Cluster 3** : UK

IV Interprétation