TP3_RL

Vincent LE MEUR

2023-05-12

TP3 : Séléction de modèle

Compte rendu

Dans un premier on importe le fichier csv:

```
library(readr)
cornell <- read_csv("cornell.csv")
```

```
##
## -- Column specification --------------------------------------------------------
## cols(
##   X1 = col_double(),
##   X2 = col_double(),
##   X3 = col_double(),
##   X4 = col_double(),
##   X5 = col_double(),
##   X6 = col_double(),
##   X7 = col_double(),
##   Y = col_double()
## )
```

Table 1: Données Cornell

X1	X2	X3	X4	X5	X6	X7	Y
0.00	0.23	0.00	0.00	0.00	0.74	0.03	98.7
0.00	0.10	0.00	0.00	0.12	0.74	0.04	97.8
0.00	0.00	0.00	0.10	0.12	0.74	0.04	96.6
0.00	0.49	0.00	0.00	0.12	0.37	0.02	92.0
0.00	0.00	0.00	0.62	0.12	0.18	0.08	86.6
0.00	0.62	0.00	0.00	0.00	0.37	0.01	91.2
0.17	0.27	0.10	0.38	0.00	0.00	0.08	81.9
0.17	0.19	0.10	0.38	0.02	0.06	0.08	83.1
0.17	0.21	0.10	0.38	0.00	0.06	0.08	82.4
0.17	0.15	0.10	0.38	0.02	0.10	0.08	83.2
0.21	0.36	0.12	0.25	0.00	0.00	0.06	81.4
0.00	0.00	0.00	0.55	0.00	0.37	0.08	88.1

Question 1 :

Réaliser les statistiques descriptives univariées et bivariées (y versus les autres variables)

On réalise dans un premier temps la descriptive univariéés:

```
summary(cornell)
```

```
##        X1                X2               X3                X4
##  Min.   :0.00000   Min.   :0.0000   Min.   :0.00000   Min.   :0.0000
##  1st Qu.:0.00000   1st Qu.:0.0750   1st Qu.:0.00000   1st Qu.:0.0000
##  Median :0.00000   Median :0.2000   Median :0.00000   Median :0.3150
##  Mean   :0.07417   Mean   :0.2183   Mean   :0.04333   Mean   :0.2533
##  3rd Qu.:0.17000   3rd Qu.:0.2925   3rd Qu.:0.10000   3rd Qu.:0.3800
##  Max.   :0.21000   Max.   :0.6200   Max.   :0.12000   Max.   :0.6200
##        X5                X6               X7                Y
##  Min.   :0.00000   Min.   :0.0000   Min.   :0.01000   Min.   :81.40
##  1st Qu.:0.00000   1st Qu.:0.0600   1st Qu.:0.03750   1st Qu.:82.92
##  Median :0.01000   Median :0.2750   Median :0.07000   Median :87.35
##  Mean   :0.04333   Mean   :0.3108   Mean   :0.05667   Mean   :88.58
##  3rd Qu.:0.12000   3rd Qu.:0.4625   3rd Qu.:0.08000   3rd Qu.:93.15
##  Max.   :0.12000   Max.   :0.7400   Max.   :0.08000   Max.   :98.70
```

On réalise ensuite la descriptive bivariéés:

Table 2: Tableau des corrélations entre Y et les autres variables

Y	
-0.837295761959791	X1
-0.0708188750487884	X2
0.493799047245563	X5
-0.706713538364348	X4
0.493799047245563	X5
0.985070413923961	X6
-0.74111624382485	X7

On constate que X6 est la variable la plus corrêlée à Y

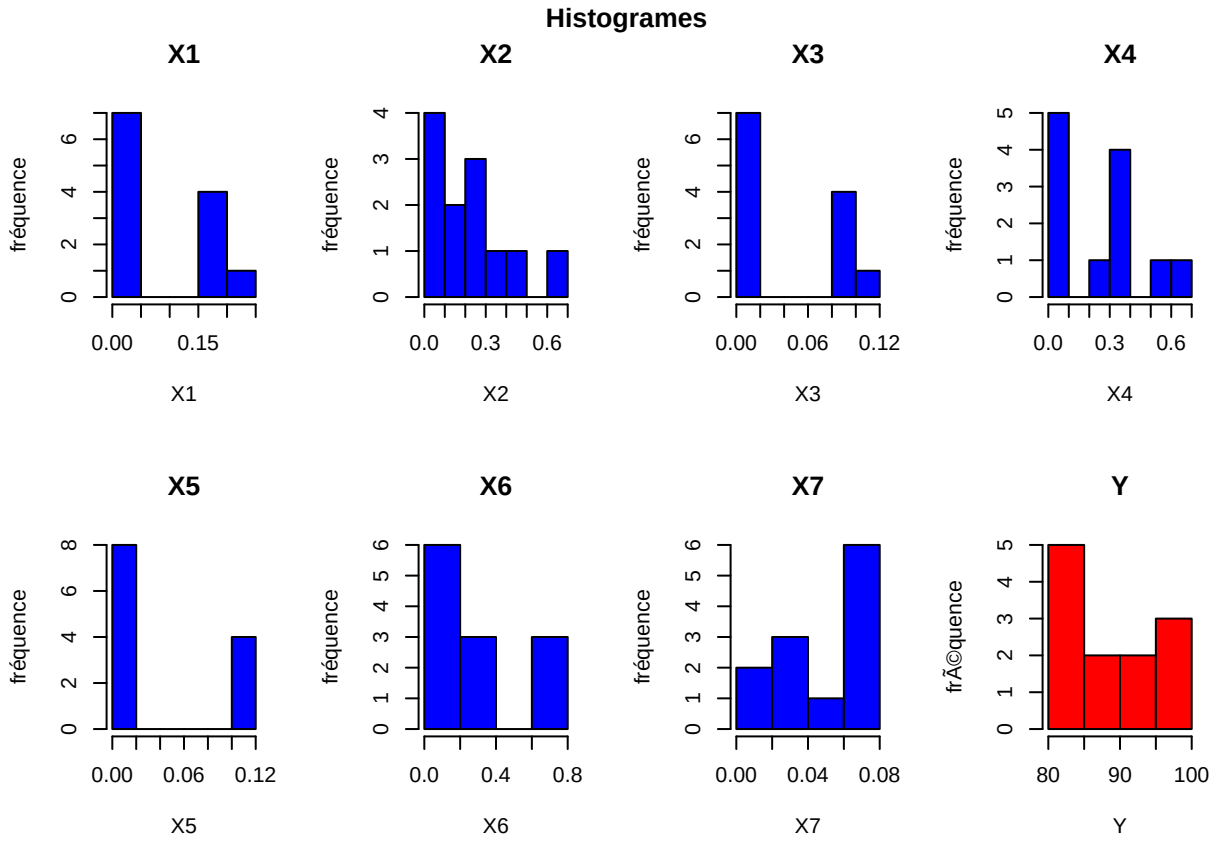
Histogrames
X1
X2
X3
X4
X5
X6
X7
Y
fréquence
frÃ©quence
0.00
0.15
0.0
0.3
0.6
0.06
0.12
0.4
0.8
0.04
0.08
80
90
100

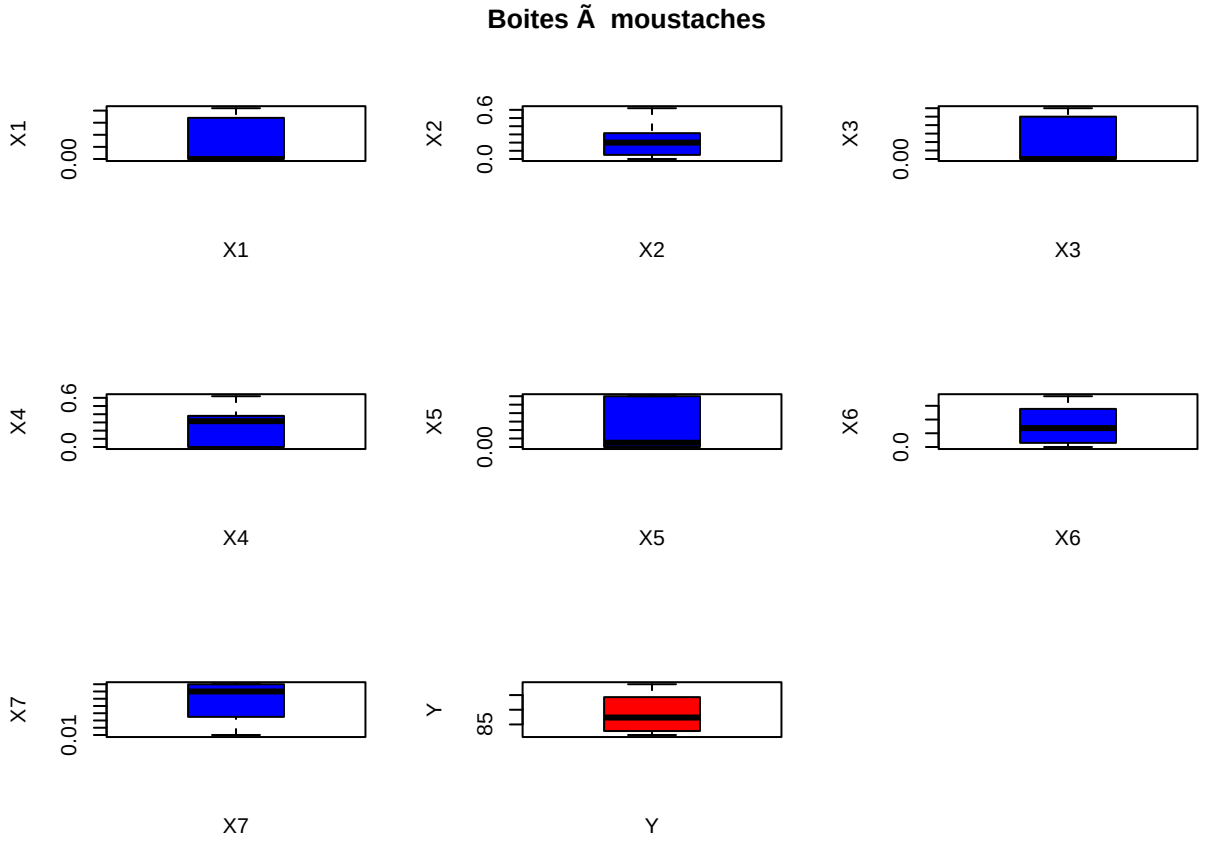
Boites Ã moustaches
X1
X2
X3
X4
X5
X6
X7
Y
0.00
0.6
0.0
0.01
85

Question 2 :

Réaliser le modèle de régression linéaire entre y et toutes les autres variables (fonction R : lm). Que constatez vous ?

```
m1 = lm(Y~.,cornell)
summary(m1)
```

```
##
## Call:
## lm(formula = Y ~ ., data = cornell)
##
## Residuals:
##          1          2          3          4          5          6          7
##  1.207e+00 -2.218e-01 -5.475e-01 -8.195e-02  8.105e-01 -3.527e-01  5.906e-02
##          8          9         10         11         12
##  3.598e-01 -3.036e-01 -1.153e-01  1.055e-15 -8.141e-01
##
## Coefficients: (1 not defined because of singularities)
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)   116.92      81.10   1.442    0.209
## X1            -82.60     173.22  -0.477    0.654
## X2            -31.00      80.84  -0.383    0.717
## X3             24.33     431.97   0.056    0.957
## X4            -39.74      90.25  -0.440    0.678
## X5            -29.17      84.02  -0.347    0.743
## X6            -16.62      84.45  -0.197    0.852
## X7                NA         NA      NA       NA
##
## Residual standard error: 0.8362 on 5 degrees of freedom
## Multiple R-squared:  0.9925, Adjusted R-squared:  0.9836
## F-statistic: 110.7 on 6 and 5 DF,  p-value: 3.762e-05
```

On remarque que la qualité globale du modèle est de 0.99, ce qui montre la bonne capacité du modèle. De plus on observe une singularité dans la variable au niveaux de la variable 7 où il manque une valeur.

Ensuite on continue à observer le modèle:

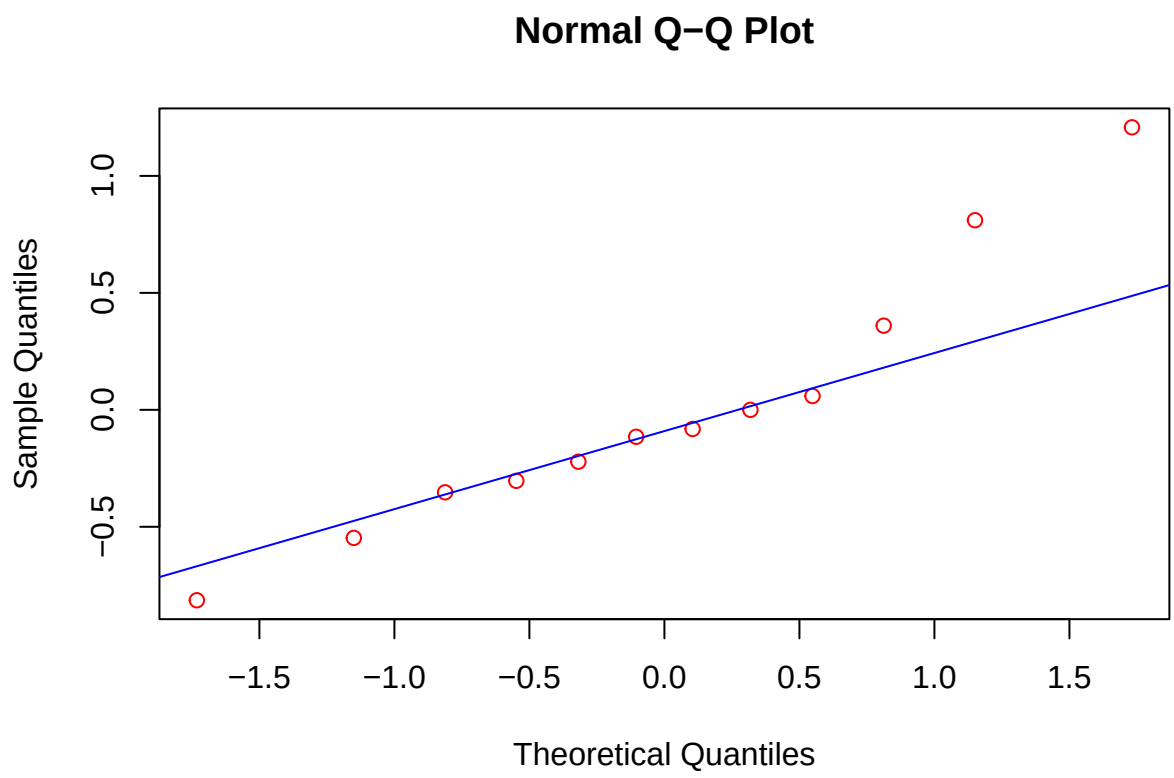


```
##
##  Shapiro-Wilk normality test
##
## data:  m1$residuals
## W = 0.93143, p-value = 0.3955
```

La p-value du test de shapito est inférieur à 0,05 ce que l'on observe aussi sur le QQ-plot ou les résidu on du mal à suivre une distribution normale.

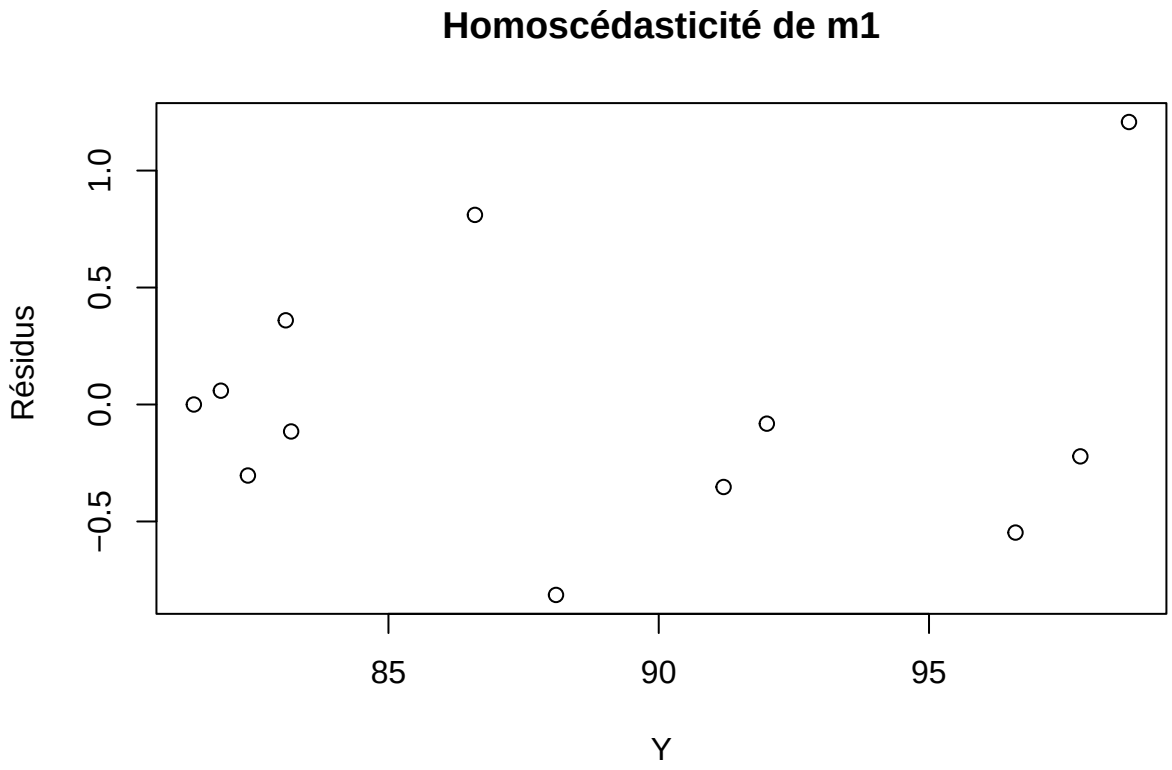

Homoscédasticité:

Et le test pour homoscédasticité : Breuch-Pagan :

```
## Le chargement a nécessité le package : zoo
```

```
##
## Attachement du package : 'zoo'
```

```
## Les objets suivants sont masqués depuis 'package:base':
##
##     as.Date, as.Date.numeric
```

```
##
##  studentized Breusch-Pagan test
##
## data:  m1
## BP = 7.4984, df = 6, p-value = 0.2772
```

De même pour l'hoscédasticité la p-value du test de Breush Pagan est inférieur à 0.05 ce qui montre qu'elle n'est pas respectée.

Indéprendance des résidus Test de Durbin-Watson :

```
## Warning in dwtest(m1): imaginary parts of eigenvalues discarded
```

```
##
##  Durbin-Watson test
##
## data:  m1
## DW = 1.6952, p-value < 2.2e-16
## alternative hypothesis: true autocorrelation is greater than 0
```

Le DW du test est de 1.6 proche de 2 donc les résidus sont non corrélés.

Etude de l'influence des observations On regarde les leviers h_{ii} :

```
## List of 4
##  $ hat         : Named num [1:12] 0.519 0.714 0.767 0.639 0.729 ...
##   ..- attr(*, "names")= chr [1:12] "1" "2" "3" "4" ...
##  $ coefficients: num [1:12, 1:7] 4.02 -41.19 131.29 -4.75 -40.33 ...
##   ..- attr(*, "dimnames")=List of 2
##   .. ..$ : chr [1:12] "1" "2" "3" "4" ...
##   .. ..$ : chr [1:7] "(Intercept)" "X1" "X2" "X3" ...
##  $ sigma       : Named num [1:12] 0.342 0.912 0.744 0.932 0.517 ...
##   ..- attr(*, "names")= chr [1:12] "1" "2" "3" "4" ...
##  $ wt.res      : Named num [1:12] 1.2075 -0.2218 -0.5475 -0.0819 0.8105 ...
##   ..- attr(*, "names")= chr [1:12] "1" "2" "3" "4" ...
```

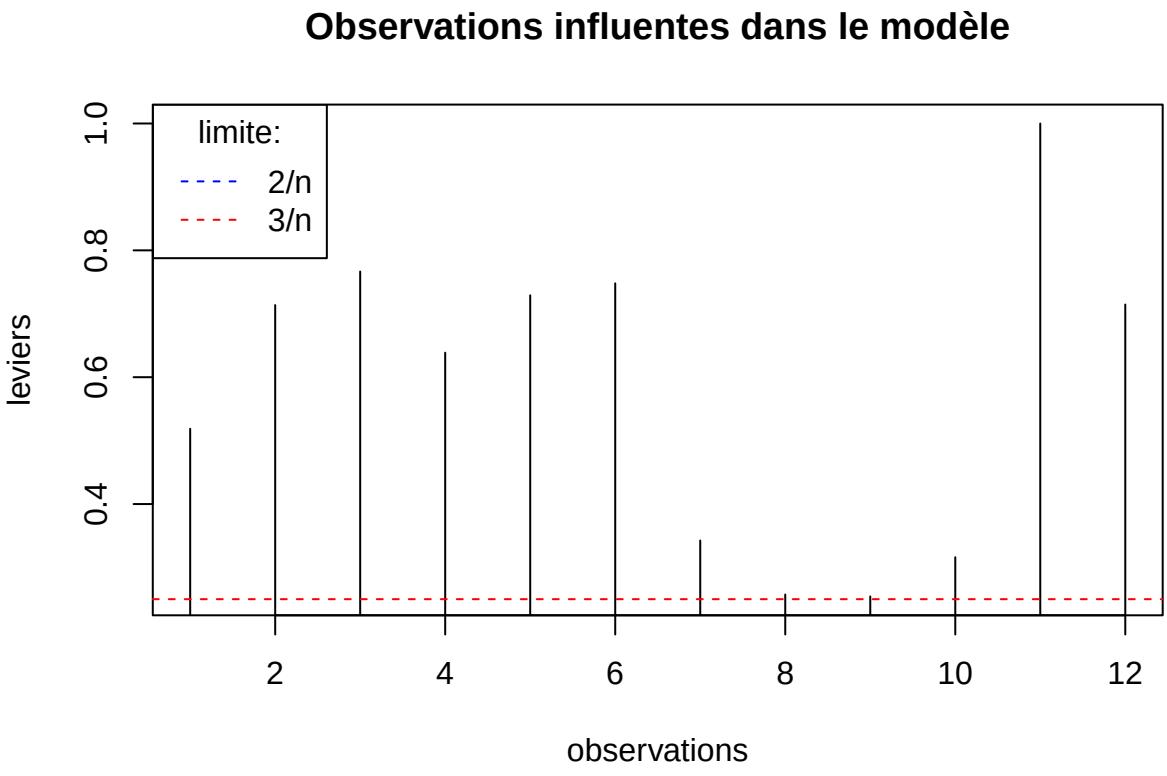

Question 3

Puisque n =12 > p=7, il ne reste qu'à vérifier qu'il n'y a pas une relation entre les variables explicatives (multi-collinéarité). En effet, les variables X's représentent les taux de chaque composante dans l'essence. Du coup, la somme sur ligne doit faire 100%. Vérifier (fonction apply). Donc on n'a pas besoin de toutes les 7 variables puisque 6 suffisent ! On calculera aussi le déterminant de la matrice XTX (voir cours). Utiliser la foction det en R.

Vérification sur la somme des variables Xi

```r
test_somme_ligne <- function( vect) {

  S <- sum(vect[1:7])
  return( S == 1)

}
```

```
test_lignes <- apply( cornell, MARGIN = 1 , FUN = test_somme_ligne)
print(test_lignes)
```

```
##  [1] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
```

On remarque bien que la somme des xi vaut 1. Donc on n'a pas besoin de toutes les 7 variables puisque 6 suffisent ! Ce qui est explique la sigularité de la variable X7.

Matrice de design

Calculer la matrice X'X

```
X= as.matrix (cbind (rep(1, nrow(cornell)), cornell[,2:7]))
library(knitr)


# Afficher la matrice X avec kable
kable(X, caption = "Matrice X")
```

Table 3: Matrice X

rep(1, nrow(cornell))	X2	X3	X4	X5	X6	X7
1	0.23	0.00	0.00	0.00	0.74	0.03
1	0.10	0.00	0.00	0.12	0.74	0.04
1	0.00	0.00	0.10	0.12	0.74	0.04
1	0.49	0.00	0.00	0.12	0.37	0.02
1	0.00	0.00	0.62	0.12	0.18	0.08
1	0.62	0.00	0.00	0.00	0.37	0.01
1	0.27	0.10	0.38	0.00	0.00	0.08
1	0.19	0.10	0.38	0.02	0.06	0.08
1	0.21	0.10	0.38	0.00	0.06	0.08
1	0.15	0.10	0.38	0.02	0.10	0.08
1	0.36	0.12	0.25	0.00	0.00	0.06
1	0.00	0.00	0.55	0.00	0.37	0.08

```
XtX <- t(X) %*% X

# Calculer le déterminant de la matrice X'X
determinant <- det(XtX)
determinant
```

```
## [1] 2.510764e-12
```

det(M) est de l'ordre de 10e-12 donc on considère que det(M) = 0 Cela signifie que **M n'est pas inversible**. On confirme bien que la solution minimisant les moindres carrés ne peut être trouvée avec ce modèle

Question 4

On ne peut pas donc faire un modèle avec toutes les variables. Mais lesquelles éliminer ? On procédera à une sélection des variables. Explorez la fonction regsubsets du package « leaps »

```
m = lm(Y~., data = cornell)
summary(m)
```

```
##
```

```
## Call:
## lm(formula = Y ~ ., data = cornell)
##
## Residuals:
##          1          2          3          4          5          6          7
##  1.207e+00 -2.218e-01 -5.475e-01 -8.195e-02  8.105e-01 -3.527e-01  5.906e-02
##          8          9         10         11         12
##  3.598e-01 -3.036e-01 -1.153e-01  1.055e-15 -8.141e-01
##
## Coefficients: (1 not defined because of singularities)
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)   116.92      81.10   1.442    0.209
## X1            -82.60     173.22  -0.477    0.654
## X2            -31.00      80.84  -0.383    0.717
## X3             24.33     431.97   0.056    0.957
## X4            -39.74      90.25  -0.440    0.678
## X5            -29.17      84.02  -0.347    0.743
## X6            -16.62      84.45  -0.197    0.852
## X7                NA         NA      NA       NA
##
## Residual standard error: 0.8362 on 5 degrees of freedom
## Multiple R-squared:  0.9925, Adjusted R-squared:  0.9836
## F-statistic: 110.7 on 6 and 5 DF,  p-value: 3.762e-05
```

```r
library(leaps)
choix = regsubsets(Y~., int= T, nbest = 1, nvmax=7, method="exh", data = cornell)
```

```
## Warning in leaps.setup(x, y, wt = wt, nbest = nbest, nvmax = nvmax, force.in =
## force.in, : 1 linear dependencies found
```

```
## Warning in leaps.setup(x, y, wt = wt, nbest = nbest, nvmax = nvmax, force.in =
## force.in, : nvmax reduced to 6
```

```r
res = summary(choix)
print(res)
```

```
## Subset selection object
## Call: regsubsets.formula(Y ~ ., int = T, nbest = 1, nvmax = 7, method = "exh",
##     data = cornell)
## 7 Variables  (and intercept)
##    Forced in Forced out
## X1     FALSE      FALSE
## X2     FALSE      FALSE
## X3     FALSE      FALSE
## X4     FALSE      FALSE
## X5     FALSE      FALSE
## X6     FALSE      FALSE
## X7     FALSE      FALSE
## 1 subsets of each size up to 6
## Selection Algorithm: exhaustive
##          X1  X2  X3  X4  X5  X6  X7
## 1  ( 1 ) " " " " " " " " " " "*" " "
## 2  ( 1 ) " " " " " " " " " " "*" "*"
## 3  ( 1 ) "*" " " " " "*" " " "*" " "
## 4  ( 1 ) "*" " " " " "*" " " "*" "*"
## 5  ( 1 ) "*" "*" " " "*" "*" "*" " "
```

```
## 6  ( 1 ) "*" "*" "*" "*" "*" "*" " "
```

```r
#choix du meilleur modèle selon le critère BIC
plot(choix, scale="bic")
```

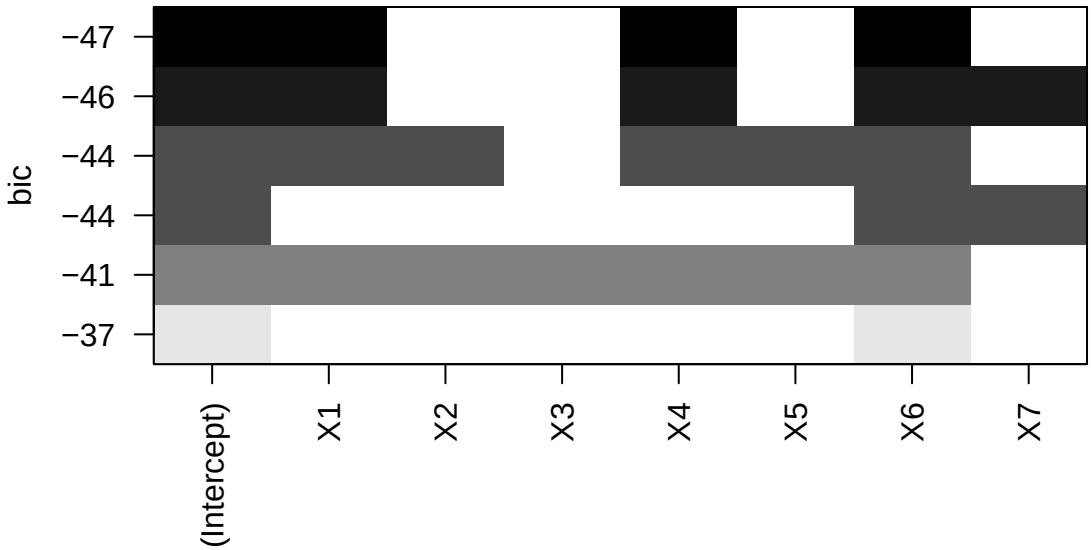

a) Quel est le meilleur modèle ? Combien de variables fait-il rentrer dans la régression ? Estimer ce modèle, analyser la validité et les performances du modèle complet (R2, significativité coefficients).

On choisit le meilleur modèle comme étant celui ayant le BIC le plus petit petit possible. On observe que le BIC le plus petit est -47. les variable **X1,X4 et X6** rentrent alors dans la régression.

Estimation de ce modèle

```r
m2=lm(Y~X1+X4+X6, data=cornell)
summary (m2)
```

```
##
## Call:
## lm(formula = Y ~ X1 + X4 + X6, data = cornell)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.00154 -0.41198  0.02205  0.29286  1.00148
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  85.9435     0.9964  86.255 3.64e-13 ***
## X1          -14.0924     4.1175  -3.423  0.00905 **
## X4           -4.9445     1.3018  -3.798  0.00525 **
## X6           15.8852     1.5779  10.067 8.07e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.707 on 8 degrees of freedom
## Multiple R-squared:  0.9915, Adjusted R-squared:  0.9882
## F-statistic: 309.3 on 3 and 8 DF,  p-value: 1.31e-08
```

La pvalue est inférieure à 1%, cela implique que le modèle statistique est significatif On à un coefficient de détermination du modèle de 99%
La p-value de X1, X4 et X6 est inférieure à 0.5 donc ces variables sont significatives.

b) quel est le meilleur modèle avec deux variables ?

```
res$outmat[2,]
```

```
##  X1  X2  X3  X4  X5  X6  X7
## " " " " " " " " " " "*" "*"
```

On constate que le meilleur modèle à deux variables est celui qui réunit **X6 et X7**

Question 5

Remplacer précédemment le critère BIC par le critère Cp, R2 ajusté (adjr2) ou encore R2.(évidemment AIC donne le mêmes résultats que BIC à cause du lien entre les deux critères).Préciser pour chaque critère le meilleur modèle.

On remplace le BIC utilisé à la question précedente

```
par(mfrow=c(2 ,2))

plot(res$bic , xlab =" nb variables " , ylab =" BIC " , type ="l")
plot(res$rss , xlab =" nb variables " , ylab =" R2 " ,type ="l")
plot(res$adjr2 , xlab =" nb variables " , ylab =" R2 ajusté " , type ="l")
plot(res$cp , xlab =" nb variables" , ylab =" Cp " ,type = "l")
```

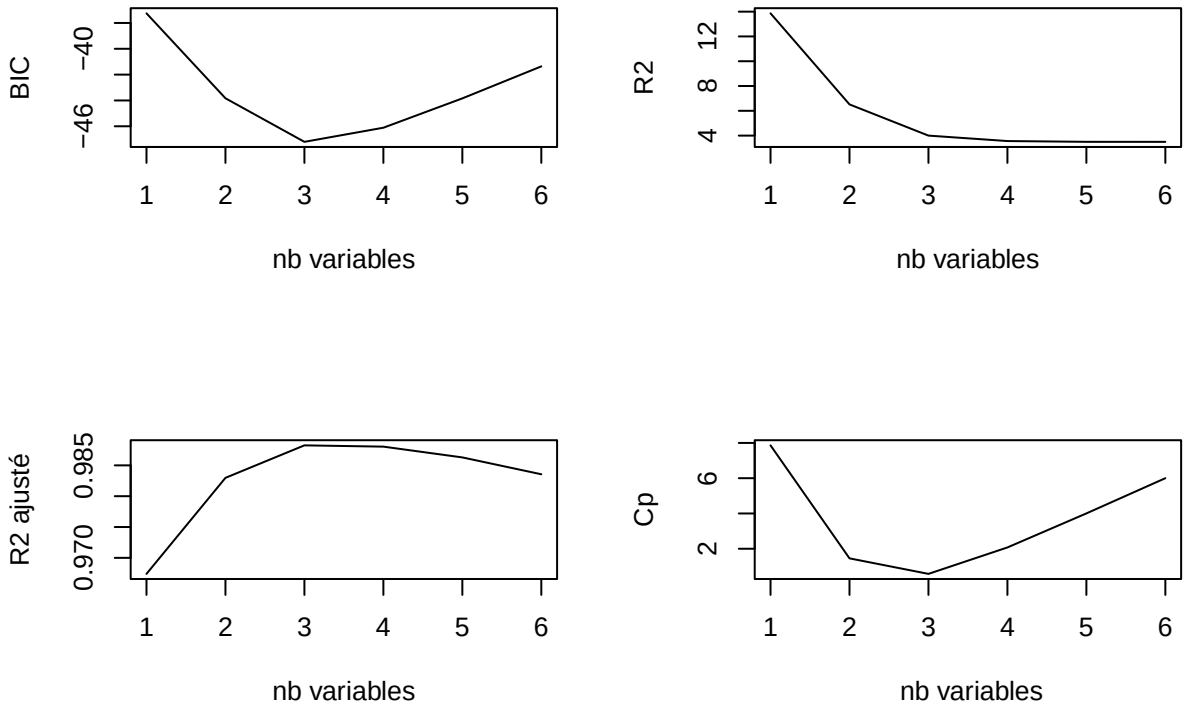


```
which.max(res$adjr2)
```

```
## [1] 3
```

```
which.min(res$cp)
```

```
## [1] 3
```

Pour tous les critères, on constate que le meilleur modèle est à trois variables. Nous allons maintenant trouver ces meilleurs modèles pour chaque critère

```
plot(choix, scale="Cp")
```

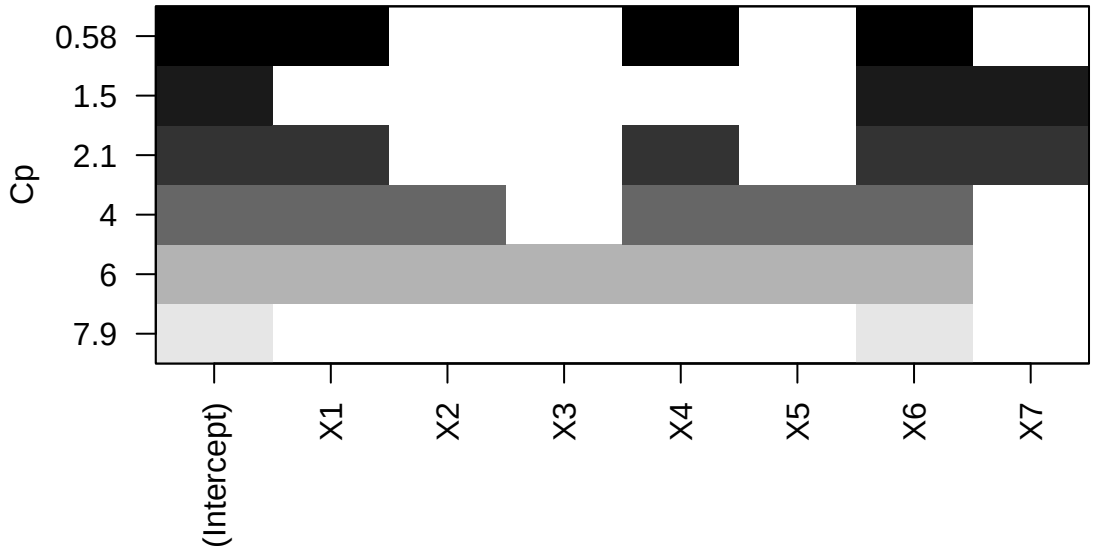

Le meilleur modèle pour Cp est celui qui contient les variables **X1, X2 et X3**.

```
plot(choix, scale="r2")
```

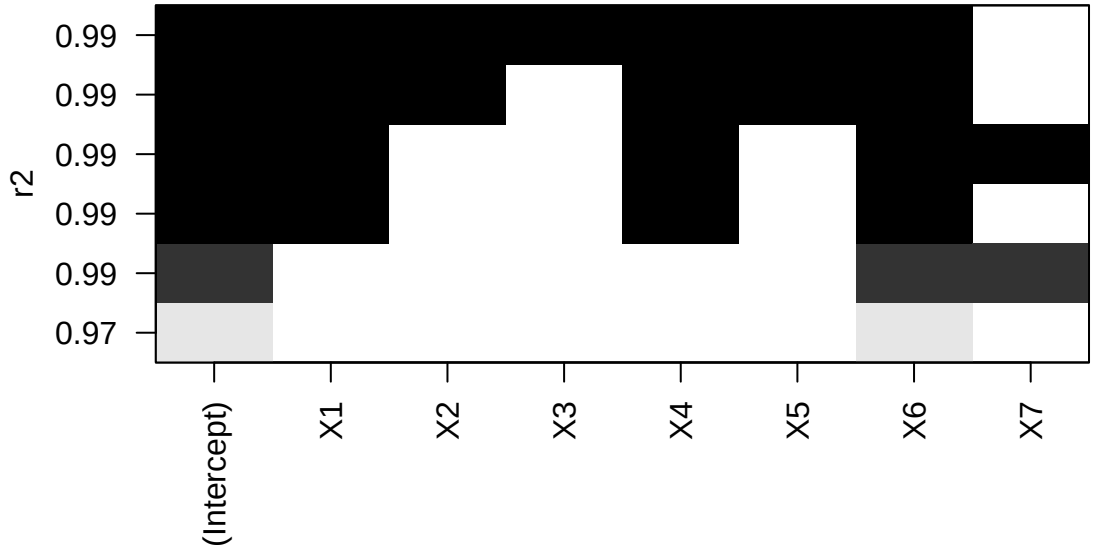

Pour R2 on ne peut pas distinguer 3 variables car à 0.99 on à toutes les variables sauf X7.

On est conclu que le meilleur modèle est le modèle qui contient les varaible **X1, X2 et X3**.

Question 6

###Les recherches précédentes étaient exhaustives. Cela pose un problème lorsque le nombre de variables est grand. Faisons une sélection de variables pas-à-pas.

```
library(MASS)
m_0 <- lm(Y ~ 1, data=cornell) # modele sans aucune variable explicative
```

```r
m_all <- lm(Y ~ ., data=cornell) # modele avec toutes les variables
m_back = stepAIC(m_all,direction="backward")
```

```
## Start:  AIC=-0.8
## Y ~ X1 + X2 + X3 + X4 + X5 + X6 + X7
##
##
## Step:  AIC=-0.8
## Y ~ X1 + X2 + X3 + X4 + X5 + X6
##
##        Df Sum of Sq    RSS      AIC
## - X3    1  0.002218 3.4983 -2.79158
## - X6    1  0.027082 3.5232 -2.70659
## - X5    1  0.084293 3.5804 -2.51329
## - X2    1  0.102814 3.5989 -2.45138
## - X4    1  0.135593 3.6317 -2.34258
## - X1    1  0.159001 3.6551 -2.26548
## <none>              3.4961 -0.79919
##
## Step:  AIC=-2.79
## Y ~ X1 + X2 + X4 + X5 + X6
##
##        Df Sum of Sq    RSS     AIC
## - X6    1   0.08997 3.5883 -4.4869
## - X5    1   0.23972 3.7380 -3.9962
## - X2    1   0.28702 3.7853 -3.8454
## - X4    1   0.36541 3.8637 -3.5994
## - X1    1   0.42297 3.9213 -3.4219
## <none>              3.4983 -2.7916
##
## Step:  AIC=-4.49
## Y ~ X1 + X2 + X4 + X5
##
##        Df Sum of Sq     RSS    AIC
## <none>                3.588 -4.487
## - X5    1     3.533   7.121  1.738
## - X2    1    50.419  54.008 26.051
## - X1    1    92.385  95.973 32.950
## - X4    1   135.027 138.615 37.362
```

```r
m_forw = stepAIC(m_0,direction="forward",scope=list(upper=m_all,lower=m_0))
```

```
## Start:  AIC=45.96
## Y ~ 1
##
##        Df Sum of Sq    RSS    AIC
## + X6    1    453.93  13.86  5.732
## + X3    1    328.47 139.32 33.423
## + X1    1    327.96 139.84 33.467
## + X7    1    256.94 210.86 38.395
## + X4    1    233.64 234.16 39.653
## + X5    1    114.07 353.73 44.604
## <none>              467.80 45.958
## + X2    1      2.35 465.45 47.897
```

```
##
## Step:  AIC=5.73
## Y ~ X6
##
##        Df Sum of Sq     RSS     AIC
## + X7    1    7.3485  6.5152 -1.3292
## + X2    1    6.7120  7.1517 -0.2106
## + X4    1    4.0095  9.8542  3.6359
## + X3    1    2.6671 11.1967  5.1685
## + X1    1    2.6534 11.2104  5.1832
## <none>              13.8638  5.7325
## + X5    1    0.8501 13.0136  6.9731
##
## Step:  AIC=-1.33
## Y ~ X6 + X7
##
##        Df Sum of Sq    RSS      AIC
## + X1    1   1.42728 5.0880 -2.29636
## + X3    1   1.38121 5.1340 -2.18821
## + X5    1   1.08694 5.4283 -1.51938
## <none>              6.5152 -1.32916
## + X4    1   0.36245 6.1528 -0.01603
## + X2    1   0.01238 6.5029  0.64802
##
## Step:  AIC=-2.3
## Y ~ X6 + X7 + X1
##
##        Df Sum of Sq    RSS     AIC
## + X4    1   1.52705 3.5609 -4.5787
## <none>              5.0880 -2.2964
## + X3    1   0.49613 4.5918 -1.5275
## + X5    1   0.44979 4.6382 -1.4071
## + X2    1   0.06527 5.0227 -0.4513
##
## Step:  AIC=-4.58
## Y ~ X6 + X7 + X1 + X4
##
##        Df Sum of Sq    RSS     AIC
## <none>              3.5609 -4.5787
## + X2    1  0.050479 3.5104 -2.7500
## + X5    1  0.049644 3.5113 -2.7472
## + X3    1  0.001742 3.5592 -2.5846
```

```
m_stepwise = stepAIC(m_0,direction="both",scope=list(upper=m_all,lower=m_0))
```

```
## Start:  AIC=45.96
## Y ~ 1
##
##        Df Sum of Sq    RSS    AIC
## + X6    1    453.93  13.86  5.732
## + X3    1    328.47 139.32 33.423
## + X1    1    327.96 139.84 33.467
## + X7    1    256.94 210.86 38.395
## + X4    1    233.64 234.16 39.653
## + X5    1    114.07 353.73 44.604
```

```
## <none>              467.80 45.958
## + X2    1      2.35 465.45 47.897
##
## Step:  AIC=5.73
## Y ~ X6
##
##        Df Sum of Sq    RSS    AIC
## + X7    1      7.35   6.52 -1.329
## + X2    1      6.71   7.15 -0.211
## + X4    1      4.01   9.85  3.636
## + X3    1      2.67  11.20  5.169
## + X1    1      2.65  11.21  5.183
## <none>               13.86  5.732
## + X5    1      0.85  13.01  6.973
## - X6    1    453.93 467.80 45.958
##
## Step:  AIC=-1.33
## Y ~ X6 + X7
##
##        Df Sum of Sq     RSS    AIC
## + X1    1     1.427   5.088 -2.296
## + X3    1     1.381   5.134 -2.188
## + X5    1     1.087   5.428 -1.519
## <none>                6.515 -1.329
## + X4    1     0.362   6.153 -0.016
## + X2    1     0.012   6.503  0.648
## - X7    1     7.349  13.864  5.732
## - X6    1   204.343 210.858 38.395
##
## Step:  AIC=-2.3
## Y ~ X6 + X7 + X1
##
##        Df Sum of Sq    RSS     AIC
## + X4    1     1.527  3.561 -4.5787
## <none>               5.088 -2.2964
## + X3    1     0.496  4.592 -1.5275
## + X5    1     0.450  4.638 -1.4071
## - X1    1     1.427  6.515 -1.3292
## + X2    1     0.065  5.023 -0.4513
## - X7    1     6.122 11.210  5.1832
## - X6    1    93.651 98.739 31.2909
##
## Step:  AIC=-4.58
## Y ~ X6 + X7 + X1 + X4
##
##        Df Sum of Sq     RSS     AIC
## - X7    1    0.4379  3.9988 -5.1868
## <none>               3.5609 -4.5787
## + X2    1    0.0505  3.5104 -2.7500
## + X5    1    0.0496  3.5113 -2.7472
## + X3    1    0.0017  3.5592 -2.5846
## - X4    1    1.5271  5.0880 -2.2964
## - X1    1    2.5919  6.1528 -0.0160
## - X6    1   12.5943 16.1552 11.5680
```

```
##
## Step:  AIC=-5.19
## Y ~ X6 + X1 + X4
##
##        Df Sum of Sq    RSS     AIC
## <none>               3.999 -5.1868
## + X7    1     0.438  3.561 -4.5787
## + X2    1     0.261  3.738 -3.9962
## + X5    1     0.214  3.785 -3.8454
## + X3    1     0.177  3.821 -3.7316
## - X1    1     5.855  9.854  3.6359
## - X4    1     7.212 11.210  5.1832
## - X6    1    50.660 54.659 24.1945
```

```r
press <- function(fit) {
  h <- lm.influence(fit)$hat
  return(sqrt(mean((residuals(fit) / (1 - h))^2)))
}

# Calcul du PRESS pour chaque modèle
press_back <- press(m_back)
press_forw <- press(m_forw)
press_stepwise <- press(m_stepwise)
```

Table 4: Comparaison des méthodes de sélection selon le PRESS

Method	PRESS
Backward	1.287098
Forward	1.012127
Stepwise	1.017572

Le meilleur modèle est celui forward qui obtient le PRESS le plus faible