TP3

Carla BUONOMO & Clara BALDACCHINO

```
cornell <- read.csv("/home/c/b/cbaldacc/Linux/RL/TP3/cornell.csv", sep=",", dec=".")
```

Question 1

Statistiques univariées

```
stat_uni = function(x)
{
return(c(length(na.omit(x)),
         length(x[is.na(x)]),
         min(x, na.rm=TRUE),
         max(x, na.rm=TRUE),
         mean(x, na.rm=TRUE),
         median(x, na.rm=TRUE),
         sd(x, na.rm=TRUE)))
}

res_stat_uni = apply(cornell, 2, "stat_uni")
row.names(res_stat_uni) = c("Nobs", "N_manq.", "Min", "Max", "Moyenne", "Mediane", "Ecart-type")

knitr::kable(round(t(res_stat_uni),3), format = "markdown", align = 'r')
```

	Nobs	N_manq.	Min	Max	Moyenne	Mediane	Ecart-type
X1	12	0	0.00	0.21	0.074	0.000	0.092
X2	12	0	0.00	0.62	0.218	0.200	0.196
X3	12	0	0.00	0.12	0.043	0.000	0.054
X4	12	0	0.00	0.62	0.253	0.315	0.227
X5	12	0	0.00	0.12	0.043	0.010	0.057
X6	12	0	0.00	0.74	0.311	0.275	0.293
X7	12	0	0.01	0.08	0.057	0.070	0.027
Y	12	0	81.40	98.70	88.583	87.350	6.521

On remarque qu'il n'y a aucune valeur manquante.

Statistiques bivariées

Il existe sept variables explicatives de Y. Pour étudier les statistiques bivariées, nous allons étudier les sept varialbes pour trouver quelles sont les plus correlées avec Y.

```
#calcul des corrélations
rescor <- cor (cornell$Y , cornell[,-8] )
row.names(rescor) = "Y"
```

```r
#affichage des corrélations
knitr::kable(round (rescor, 3), format="markdown", align ='c')
```

	X1	X2	X3	X4	X5	X6	X7
Y	-0.837	-0.071	-0.838	-0.707	0.494	0.985	-0.741

On constate que X6 est la variable la plus corrêlée à Y (de plus, elle l'est fortement) X1 et X3 sont également très corrêlée à Y. Ces variables pourraient donner un bon modèle de regression linéaire.

Question 2

Régression linéaire multiple

Entre Y et toutes les variables Xi

```r
m1=lm(Y~., data=cornell)
summary (m1)
```

```
##
## Call:
## lm(formula = Y ~ ., data = cornell)
##
## Residuals:
##          1          2          3          4          5          6          7
##  1.207e+00 -2.218e-01 -5.475e-01 -8.195e-02  8.105e-01 -3.527e-01  5.906e-02
##          8          9         10         11         12
##  3.598e-01 -3.036e-01 -1.153e-01  1.055e-15 -8.141e-01
##
## Coefficients: (1 not defined because of singularities)
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)   116.92      81.10   1.442    0.209
## X1            -82.60     173.22  -0.477    0.654
## X2            -31.00      80.84  -0.383    0.717
## X3             24.33     431.97   0.056    0.957
## X4            -39.74      90.25  -0.440    0.678
## X5            -29.17      84.02  -0.347    0.743
## X6            -16.62      84.45  -0.197    0.852
## X7                NA         NA      NA       NA
##
## Residual standard error: 0.8362 on 5 degrees of freedom
## Multiple R-squared:  0.9925, Adjusted R-squared:  0.9836
## F-statistic: 110.7 on 6 and 5 DF,  p-value: 3.762e-05
```

```r
paste(m1$coefficients)
```

```
## [1] "116.921278448511"  "-82.6010514822711" "-30.9984480541055"
## [4] "24.3306512301065"  "-39.741177941475"  "-29.1710624504537"
## [7] "-16.620449566887"  "NA"
```

On constate qu'il y a une valeur manquante pour la variable X7 à cause d'une "singularité" de la variable.

Question 3

Vérification sur la somme des variables Xi

```
test_somme_ligne <- function( vect) {

  S <- sum(vect[1:7])
  return( S == 1)

}
test_lignes <- apply( cornell, MARGIN = 1 , FUN = test_somme_ligne)
print(test_lignes)
```

```
##  [1] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
```

Chaque ligne du dataframe est bien telle que : la somme des valeurs des Xi vaut 1, soit 100% C'est pour cela que seules six variables suffisent car somme(Xi)=1 donc on peut en définir une telle que : Xk = 1 - somme(Xi) i!=k Cela représente la singularité de X7 qui avait causé une valeur manquante dans la régression effectuée à la question précedente.

Matrice de design

On a vu qu'il existait une colinearite entre nos valeurs puisque la somme de chaque ligne vaut 1. De ce fait, on ne peut pas trouver la solution qui minimise les moindres carrés : Beta = inv(M)t(X)Y

On va vérifier cela en calculant le déterminant de t(X)X

Si la solution existe, cette matrice doit être inversible

On a déjà remarqué plus haut qu'il n'y a pas de valeur manquante dans cornell. Ainsi, pas besoin d'utiliser la fonction na.omit pour créer un nouveau dataframe sans valeur manquante

```
X= as.matrix (cbind (rep(1, nrow(cornell)), cornell[,2:7]))
print(X)
```

```
##       rep(1, nrow(cornell))   X2   X3   X4   X5   X6   X7
##  [1,]                     1 0.23 0.00 0.00 0.00 0.74 0.03
##  [2,]                     1 0.10 0.00 0.00 0.12 0.74 0.04
##  [3,]                     1 0.00 0.00 0.10 0.12 0.74 0.04
##  [4,]                     1 0.49 0.00 0.00 0.12 0.37 0.02
##  [5,]                     1 0.00 0.00 0.62 0.12 0.18 0.08
##  [6,]                     1 0.62 0.00 0.00 0.00 0.37 0.01
##  [7,]                     1 0.27 0.10 0.38 0.00 0.00 0.08
##  [8,]                     1 0.19 0.10 0.38 0.02 0.06 0.08
##  [9,]                     1 0.21 0.10 0.38 0.00 0.06 0.08
## [10,]                     1 0.15 0.10 0.38 0.02 0.10 0.08
## [11,]                     1 0.36 0.12 0.25 0.00 0.00 0.06
## [12,]                     1 0.00 0.00 0.55 0.00 0.37 0.08
```

```
M = t(X) %*% X

det ( M )
```

```
## [1] 2.510764e-12
```

det(M) est de l'ordre de 10e-12 donc on considère que det(M) = 0 Cela signifie que **M n'est pas inversible**. On confirme bien que la solution minimisant les moindres carrés ne peut être trouvée avec ce modèle

Il faut procéder à **l'élimination de variables** pour échapper à cette multicolinéarité

Question 4

Quels variables éliminer ?

```r
m = lm(Y~., data = cornell)

library(leaps)
choix = regsubsets(Y~., int= T, nbest = 1, nvmax=7, method="exh", data = cornell)
```

```
## Warning in leaps.setup(x, y, wt = wt, nbest = nbest, nvmax = nvmax, force.in =
## force.in, : 1 linear dependencies found
```

```
## Warning in leaps.setup(x, y, wt = wt, nbest = nbest, nvmax = nvmax, force.in =
## force.in, : nvmax reduced to 6
```

```r
res = summary(choix)
print(res)
```

```
## Subset selection object
## Call: regsubsets.formula(Y ~ ., int = T, nbest = 1, nvmax = 7, method = "exh",
##     data = cornell)
## 7 Variables  (and intercept)
##    Forced in Forced out
## X1     FALSE      FALSE
## X2     FALSE      FALSE
## X3     FALSE      FALSE
## X4     FALSE      FALSE
## X5     FALSE      FALSE
## X6     FALSE      FALSE
## X7     FALSE      FALSE
## 1 subsets of each size up to 6
## Selection Algorithm: exhaustive
##          X1  X2  X3  X4  X5  X6  X7
## 1  ( 1 ) " " " " " " " " " " "*" " "
## 2  ( 1 ) " " " " " " " " " " "*" "*"
## 3  ( 1 ) "*" " " " " "*" " " "*" " "
## 4  ( 1 ) "*" " " " " "*" " " "*" "*"
## 5  ( 1 ) "*" "*" " " "*" "*" "*" " "
## 6  ( 1 ) "*" "*" "*" "*" "*" "*" " "
```

```r
#choix du meilleur modèle selon le critère BIC
plot(choix, scale="bic")
```

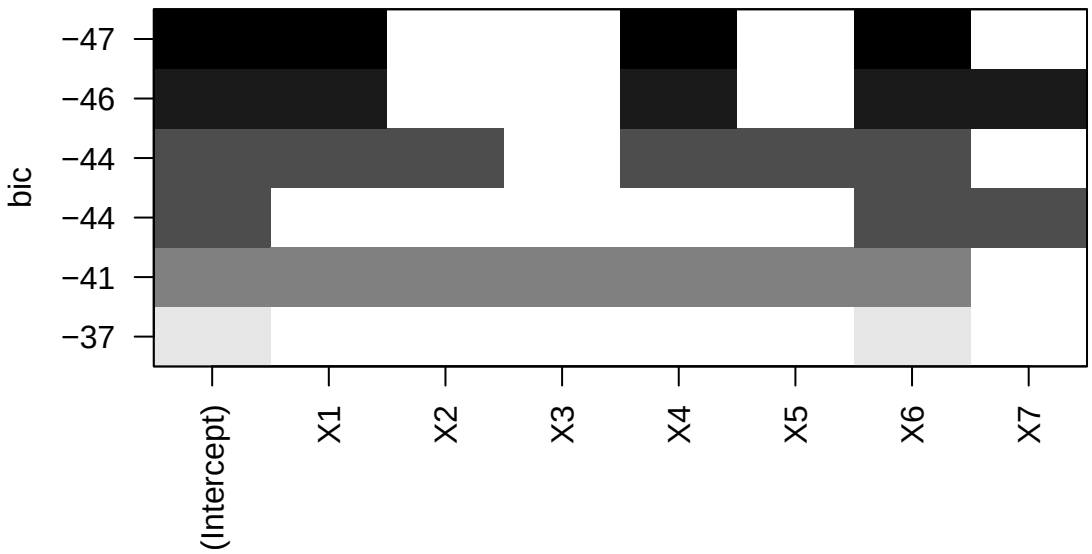

4.a / Quel est le meilleur modèle ? Combien de variables fait-il rentrer dans la régression ?

On choisit le meilleur modèle comme étant celui ayant le BIC le plus petit petit possible. Le BIC minimum est ici de -47 et il correspond au modèle qui réunit les variables **X1 , X4 et X6** (On aurait pu également utiliser R**2 pour choisir le meilleur modèle)

Le meilleur modèle fait donc entrer trois variables dans la régression.

La fonction regsubsets nous montre que cette configuration représente le meilleur modèle à 3 variables. Elle nous donne également les meilleurs modèles, quelque soit le nombre de variables souhaitées.

Estimation de ce modèle

```
m2=lm(Y~X1+X4+X6, data=cornell)
summary (m2)
```

```
##
## Call:
## lm(formula = Y ~ X1 + X4 + X6, data = cornell)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.00154 -0.41198  0.02205  0.29286  1.00148
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  85.9435     0.9964  86.255 3.64e-13 ***
## X1          -14.0924     4.1175  -3.423  0.00905 **
## X4           -4.9445     1.3018  -3.798  0.00525 **
## X6           15.8852     1.5779  10.067 8.07e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.707 on 8 degrees of freedom
## Multiple R-squared:  0.9915, Adjusted R-squared:  0.9882
## F-statistic: 309.3 on 3 and 8 DF,  p-value: 1.31e-08
```

- La pvalue est inférieure à 1% : notre modèle statistique est significatif

- Le coefficient de détermination vaut 0.9915 : 99.15 % de Y est expliquée par les variables explicatives X1,X4 et X6
- Les trois variables sont significatives car leur pvalue sont toutes inférieures à 5%. On remarque tout de même qu'il y a un écart de 10e-3 entre les pvalue de X1 et X4 et celle de X6. X6 semble plus significative encore que les autres. (au début de l'analyse, on avait déjà remarqué que X6 était la variable la plus corrélée avec Y)

4.b / Le meilleur modèle à deux variables ?

```
res$outmat[2,]
```

```
##  X1  X2  X3  X4  X5  X6  X7
## " " " " " " " " " " "*" "*"
```

Grâce à la fonction regsubsets, on constate que le meilleur modèle à deux variables est celui qui réunit **X6 et X7**

Question 5

On remplace le BIC utilisé à la question précedente

Tout d'abord, on étudie tous les autres critères de choix de modèle de manière générale. Ces critères sont:

- Le R2
- Le R2 ajusté
- Le Cp de Mallows

```
par(mfrow=c(2 ,2))

plot(res$bic , xlab =" nb variables " , ylab =" BIC " , type ="l")
plot(res$rss , xlab =" nb variables " , ylab =" R2 " ,type ="l")
plot(res$adjr2 , xlab =" nb variables " , ylab =" R2 ajusté " , type ="l")
plot(res$cp , xlab =" nb variables" , ylab =" Cp " ,type = "l")
```

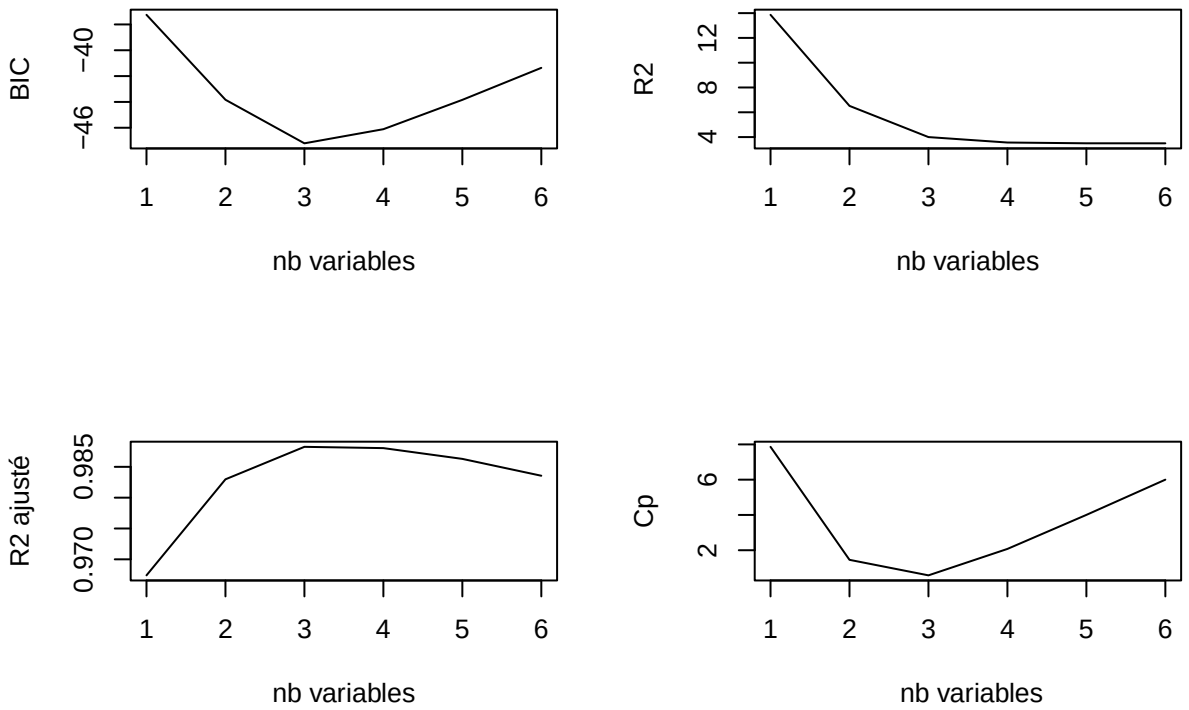


```
which.max(res$adjr2)
```

```
## [1] 3
```

```
which.min(res$cp)
```

```
## [1] 3
```

```
which.min(res$bic)
```

```
## [1] 3
```

Pour tous les critères, on constate que le meilleur modèle est à trois variables. Nous allons maintenant trouver ces meilleurs modèles pour chaque critère

Le meilleur modèle pour le Cp

On cherche le meilleur modèle à trois variables pour le Cp. Ce meilleur correspond à celui dont le Cp est le plus proche de 3+1=4

```
plot(choix, scale="Cp")
```

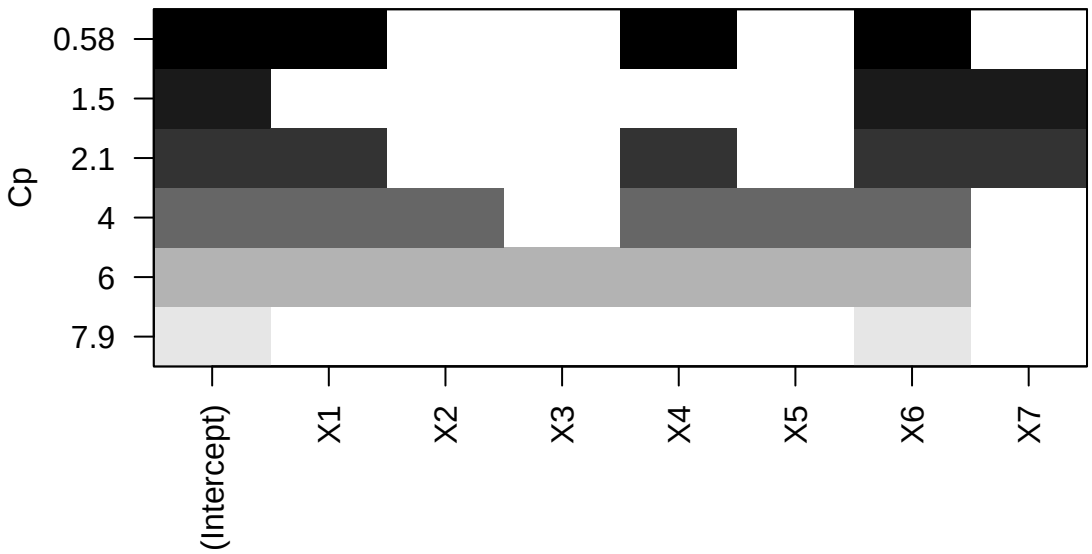

Le meilleur modèle à trois variables est celui qui regroupe **X1, X4 et X6** (même résultat qu'avec le BIC)

Le Cp de ce modèle vaut 0.58. Donc Delta = abs (4-Cp) = 3.42

Le meilleur modèle pour le R2

On cherche le meilleur modèle à trois variables pour le R2. Ce meilleur correspond à celui dont le R2 est maximal

```
plot(choix, scale="r2") # SERAIT IL POSSIBLE DE CHANGER AXE POUR AVOIR PLUS DE CHIFFRES SIGNIFICATIFS ?
```

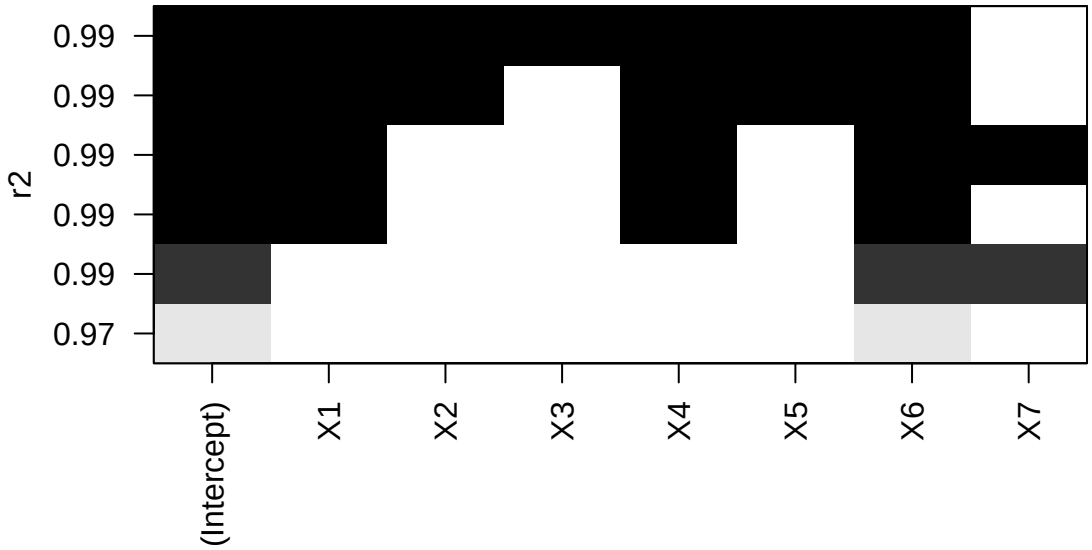

Le meilleur modèle à trois variables est celui qui regroupe **X1, X4 et X6** (même résultat qu'avec le BIC et Cp) Pour ce modèle, le R2 a une valeur de 0.99 ce qui signifie que 99% de l'informationde Y est apportée par les variables explicatives du modèle.

Le meilleur modèle pour le R2 ajusté

```
plot(choix, scale="adjr2")
```

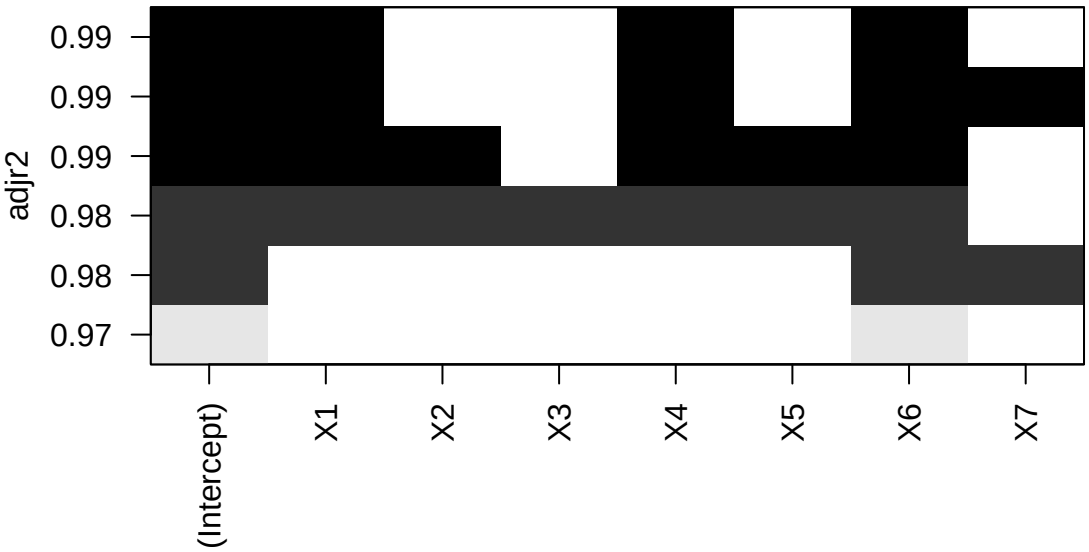

De même ici, Le meilleur modèle à trois variables est celui qui regroupe **X1, X4 et X6** (même résultat qu'avec le BIC , Cp et R2) Pour ce modèle, le R2 ajusté a une valeur de 0.99